결 과 보 고 서

과제명: 반도체 결함 패턴 분류를 위한 Score Margin 기반

난이도 적응형 Tiny NPU Datapath 설계

— OpenROAD(ORFS) 기반 ASAP7 7 nm PPA 비교 분석

팀　　명: Pin_Pineapple_Applepen(PPA)

이화여자대학교 전자전기공학과 윤현서, 최서현, 윤홍은

지도교수: 최종윤

경북대학교 IDEC 2026 창의 회로설계 챌린지

목차

요약 3

1. 과제 개요 4

2. 설계 목표 5

3. 설계 및 시뮬레이션 6

3.1 전체 구조 및 데이터 흐름 7

3.2 Score Margin 기반 난이도 판단과 Top-2 Finder 개선 8

3.3 소프트웨어 모델링, 임계값 탐색, 정수 양자화 10

3.4 RTL 설계와 주최 측 인터페이스 호환 14

3.5 기능 검증 15

3.6 논리 합성 및 타이밍 (OpenROAD-flow-scripts, ASAP7) 24

3.7 게이트레벨 VCD 기반 전력 및 추론당 에너지 26

3.8 Medium 경로의 기여 분리 30

3.9 자유주제: WM-811K 웨이퍼맵 결함 분류 적용 32

3.10 입력 열화에 따른 적응적 연산 배분 (RTL 실측) 36

4. 결과 및 기대효과 38

4.1 결과 요약 38

4.2 한계 및 향후 개선 38

4.3 기대효과 39

4.4 결론 39

※ 참고문헌 40

부록 A. 재현성 41

부록 B. 관련 연구 비교 42

부록 C. 추가 그림 42

요약

본 과제는 입력마다 Early Classifier 점수의 Top-1 과 Top-2 차이(Score Margin)를 비교기와 감산기만으로 계산하여 Easy / Medium / Hard 경로를 선택하는 난이도 적응형 NPU Datapath(AdaPath-NPU)를 설계하였다. 지정주제(MNIST)에서는 주최 측 Reference 와 같은 주 경로 신경망(모델 A)을 사용하여, 주최 입력 순차 1,000 회 기준 **정답 수를 970 회로 유지하면서 평균 처리 cycle(36.1 % 감소)과 추정 Fmax 기준 추론 지연(33.0 % 감소)을 함께 줄였다**. ASAP7 pre-layout 게이트레벨 VCD 기반 추론당 에너지는 8.9 % 감소이며, 면적은 Feature Map Buffer 와 Early Classifier 추가로 55.4 % 증가이다. Top-2 Finder 를 토너먼트 트리로 변경한 후, 합성 직후 추정 Fmax 는 판단 회로가 없는 Baseline_A 와 거의 같았다(AdaPath_A 543.1 MHz, Baseline_A 543.3 MHz). 다만 Reference 의 569.8 MHz 보다는 낮았다. 배치와 전역 배선까지 수행한 결과에서는 FSM enable 신호의 배선 지연으로 Fmax 차이가 다시 커졌지만, 추론 지연은 여전히 Reference 보다 28.0 % 짧았다. 또한 블록별 에너지 분해로 **MAC 감소가 그대로 에너지 감소로 이어지지 않는 원인(후단부 레지스터의 유휴 소모)을 정량화하였다**. 후단부 클럭 게이팅을 적용하면 추론당 에너지는 상한 추정으로 Reference 대비 28.7 % 감소에 이르며, 전용 ICG 셀을 실제로 넣은 설계의 배치 전 평가에서도 선정 구간의 에너지가 게이팅 전보다 20.7~25.9 % 줄었다.

자유주제(WM-811K 웨이퍼맵 4-class)에서는 같은 기법을 3-경로 모델에 적용하여, 주최 측 chip 인터페이스를 유지한 RTL 이 **954 장 전부에서 정수 Golden 과 판정, 모드, Score Margin 이 비트 단위로 일치함(954 / 954)**을 Vivado 로 확인하였고, Easy / Medium / Hard 세 경로가 모두 사용됨(404 / 167 / 383 장)을 보였다. 아울러 2-fold 교차 평가, 정확도 차이의 통계 검정, 입력 열화 실험을 통해 적응형 경로의 이득이 성립하는 조건과 한계를 함께 제시하였다.

핵심어: Early-Exit, Score Margin, 적응형 추론, NPU, ASAP7, OpenROAD, 게이트레벨 전력, WM-811K

1. 과제 개요

고정 경로 CNN 가속기는 입력 난이도와 관계없이 모든 입력에 동일한 연산 경로를 수행한다. 그러나 실제 입력의 상당수는 얕은 특징만으로도 분류가 가능하며, **이들에게 전체 경로를 적용하는 것은 연산, 시간, 에너지의 낭비이다**. 본 과제는 전단부(Conv1) 직후 **Early Classifier 점수의 Top-1 과 Top-2 차이(Score Margin)**를 난이도 지표로 사용하여, 입력마다 Easy / Medium / Hard 경로 중 하나를 선택하는 **난이도 적응형 NPU Datapath(AdaPath-NPU)**를 설계하였다.

엔트로피 기반 Early-Exit 기법(BranchyNet 등)은 분기 판단에 확률 분포의 엔트로피를 사용하므로 확률, 로그 계산 또는 그 근사 회로가 필요하다. 본 설계는 **비교기와 감산기만으로 계산되는 Score Margin 을 사용하며**, 같은 판단 결과로 후단 연산을 생략(Easy)하거나 일부 채널만 활성화(Medium)한다.

관련 연구로, BranchyNet[1]은 엔트로피 기반 조기 종료와 여러 출구의 공동 학습을 제시하였고, Shallow-Deep Networks[7]는 최대 클래스 확률에 따른 조기 종료와 과도한 후단 계산의 영향을 분석하였다. CascadeCNN[6]은 확률 벡터의 Best-vs-Second-Best 계열 지표로 저정밀도 추론과 고정밀도 재계산을 선택하였다(부록 B). 이들 연구가 주로 소프트웨어나 FPGA 수준에서 조기 종료의 정확도와 연산량을 다룬 것과 달리, **본 설계는 정수 로짓 차이를 비교기와 감산기만으로 계산하는 판단 회로, 공유 전단부와 3 단계 경로 선택, 주최 측 인터페이스 통합을 하나의 RTL 로 구현**하고, ASAP7 합성, 배치와 STA, 게이트레벨 VCD 기반 전력 분석까지 연결하여 하드웨어 비용과 이득을 함께 정량화하였다. 주최 측 평가 구조에 맞추어 과제를 다음과 같이 구성하였다.

[표 1] 평가 항목별 과제 구성

구분	대상 모델 / 데이터	수행 내용
지정주제 (50 %)	주최 측 MNIST 레퍼런스 가속기와 주 경로 계층 및 채널 구성이 같은 모델 A	같은 주 경로에 AdaPath 적용 → 정확도 유지 조건에서 PPA 비교
자유주제 (30 %)	WM-811K 웨이퍼맵 결함 분류 (4 개 클래스, 모델 B)	같은 기법의 적용 전후 (Baseline_WM vs AdaPath_WM) PPA 비교
확장 실험	MNIST, 확장 모델 B (Conv2 8 채널)	후단부가 큰 모델에서 Medium 경로의 기여 분리

[표 2] 비교 설계 대응표 (모두 동일 RTL 소스 adapath_top.v 에서 파라미터로 생성, Reference 제외)

설계	VARIANT	Conv2 / Medium 채널	클래스	데이터	비고
Reference	-	3 / -	10	MNIST	주최 측 chip.v, 항상 전체 경로
Baseline_A	0	3 / -	10	MNIST	본 팀 데이터패스, 항상 Hard, Early Classifier 없음
AdaPath_A	2	3 / 1	10	MNIST	**지정주제 제출 설계**
Baseline_B	0	8 / -	10	MNIST	확장 모델, 항상 Hard
Early-Exit_B	1	8 / -	10	MNIST	Medium 없는 2 경로 (기여 분리용)
AdaPath_B	2	8 / 4	10	MNIST	확장 모델 3 경로
Baseline_WM / AdaPath_WM	0 / 2	8 / 4	4	WM-811K	자유주제 (N_CLASS=4, 가중치, 임계값, shift 별도)

모델 A 는 Reference 와 주 경로(Conv1 3 채널 → Conv2 3 채널 → FC 48→10)의 계층 및 채널 구성이 같다. 다만 가중치는 본 팀이 학습한 값이고, 정수 규약(가중치 INT8, 활성값 12-bit, bias 16-bit)과 Early Classifier 추가가 다르다. ASIC 합성에서는 세 설계 모두 **가중치를 입력 포트로 두어 상수 전파 효과를 배제하였다**.

본 과제의 기여는 다음 세 가지이다. 첫째, Score Margin 으로 입력 난이도를 판정하고 공통 전단부 이후의 연산 경로를 선택하는 스트리밍 데이터패스를 구현하였다. Easy 입력은 후단 추론을 생략하며, Medium 과 Hard 입력은 저장한 특징을 재생하여 일부 또는 전체 Conv2 채널을 사용한다. 둘째, Top-2 탐색을 직렬 비교 체인에서 이진 토너먼트 트리로 바꾸어, **처리 cycle 증가 없이 판단 회로의 조합 경로를 단축하였다**. 셋째, 주최 측 Reference 와 항상 Hard 경로를 실행하는 Baseline_A 를 함께 비교하여 **데이터패스 변경 효과와 적응형 경로 선택 효과를 분리하였다**. 모델 A 는 선정 임계값에서 Easy/Hard 두 경로를 사용하며, Medium 경로의 기여는 확장 모델에서 별도로 평가하였다.

핵심 결과: 지정주제에서 Reference 와 같은 970 / 1,000 정답을 유지하면서 **평균 처리 cycle 36.1 %, 추론 지연 33.0 %, 추론당 에너지 8.9 %를 줄였다**(면적 55.4 % 증가). 후단부 클럭 게이팅을 적용하면 구간별 에너지가 추가로 20.7~25.9 % 줄었고, 같은 설계를 자유주제 WM-811K 에 적용하여 3 경로 제어가 실제로 동작함을 확인하였다.

2. 설계 목표

지정주제의 전제 조건(정확도 유지)에서 PPA 개선을 목표로 하되, 다음 세 가지를 평가 원칙으로 정하였다. ① **연산량(MAC) 감소가 아니라 게이트레벨 스위칭 기반의 추론당 에너지로 평가한다**. ② 판단 회로가 동작 주파수를 낮추지 않아야 한다. ③ Medium 경로의 기여는 Medium 이 없는 2 경로 구조와 분리하여 평가한다.

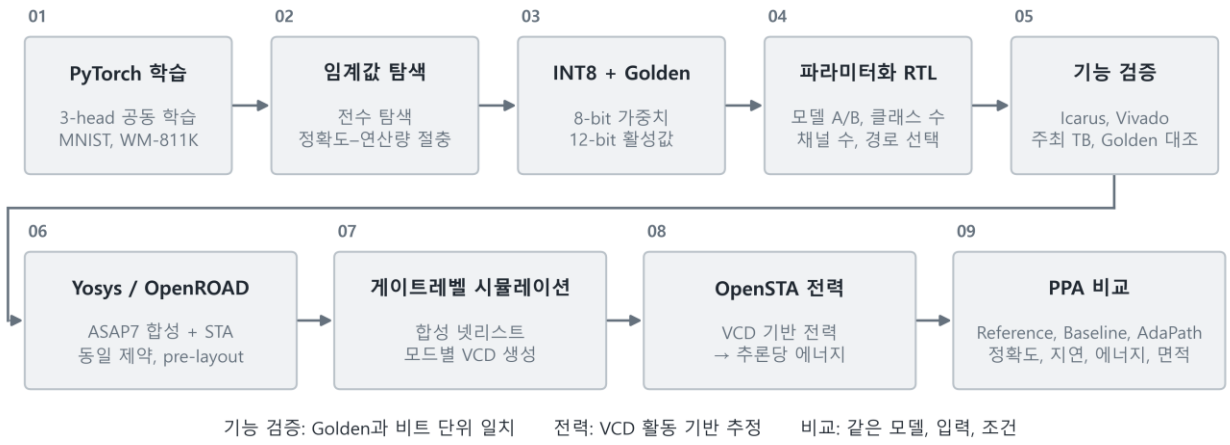
[표 3] 설계 목표 및 결과 (지정주제: Reference 대비 AdaPath_A)

항목	목표	결과	판정
분류 정확도	Reference 이상 유지	970 / 1,000 (Reference 970 / 1,000, 주최 입력 순차 실행)	달성
평균 처리 cycle	Reference 대비 단축	1,334 → 852 cycle (36.1 % 감소)	달성
추론 지연 (pre-layout Fmax 기준)	Reference 대비 단축	2,341 → 1,569 ns (33.0 % 감소)	달성
추론당 에너지	Reference 대비 감소	17.7 → 16.2 nJ (8.9 % 감소, VCD 기반 추정)	달성
최대 동작 주파수	판단 회로로 인한 저하 없음	Baseline_A 543.3 / AdaPath_A 543.1 MHz (Reference 569.8 MHz)	달성
판단 및 제어 회로 면적	전체 면적의 5 % 이내	325.1 μm² (AdaPath_A 의 0.65 %, 단독 합성 기준 참고치)	달성
입출력 인터페이스	Reference 와 동일	동일 포트 래퍼, 주최 측 TB 로직 무수정 실행	달성
자유주제 (WM-811K)	적용 전후 PPA 개선	MAC 23.5 % 감소, 정확도 0.31 %p 하락, 에너지 21.7 % 감소 (대리 추정)	부분 확인

면적은 처리 cycle 을 줄이기 위한 병렬 데이터패스와 적응형 경로의 추가로 Reference 보다 증가한다. 증가분의 대부분은 병렬 연산기에서 발생하며 판단 회로 자체는 전체의 1 % 미만이다(3.6 절). 면적 투자가 지연과 에너지 이득으로 전환되는 정도를 3.6~3.7 절과 4 장에서 정량적으로 분석한다. WM 자체의 전력 평가는 미완료이며, 에너지 감소율은 대리 추정이다.

3. 설계 및 시뮬레이션

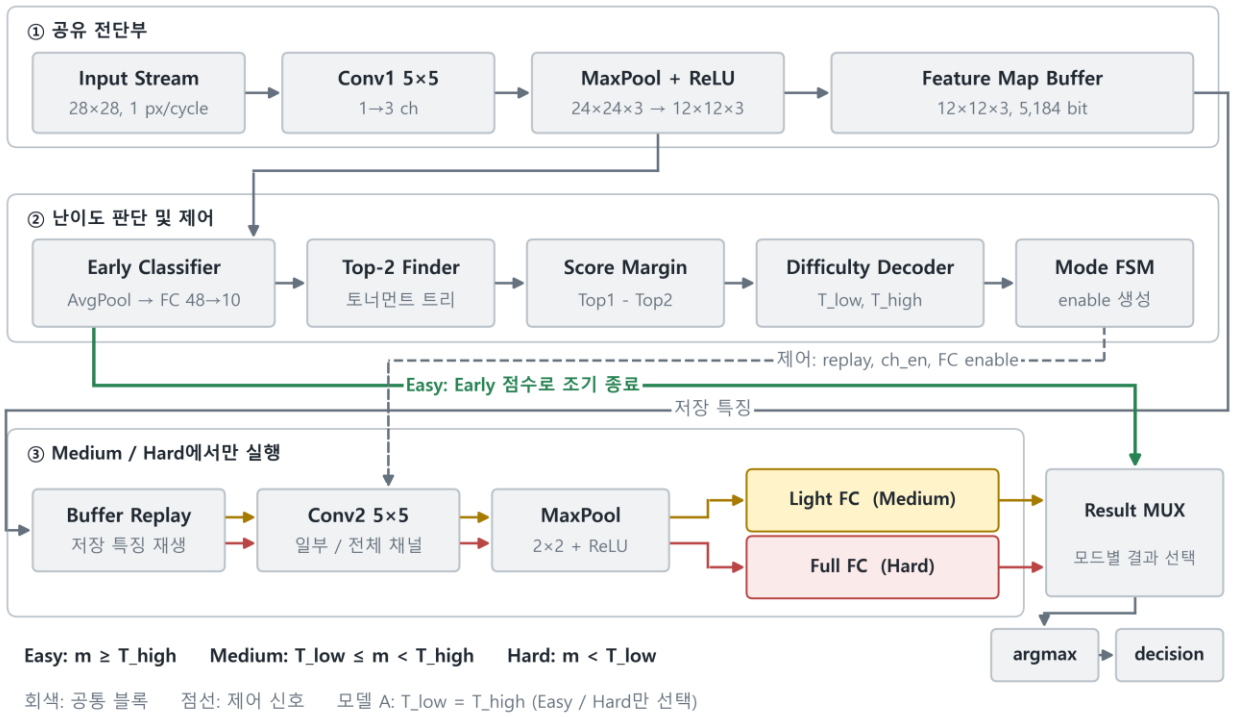
그림 1 은 학습부터 PPA 비교까지의 전체 설계 및 평가 흐름이다. 기능 검증은 Golden 모델과의 비트 정합으로, 전력은 게이트레벨 VCD 활동 기반 추정으로, 비교는 동일 모델, 입력, 조건을 명시하여 수행하였다.



[그림 1] AdaPath-NPU 설계 및 평가 흐름

3.1 전체 구조 및 데이터 흐름

AdaPath-NPU 는 세 영역으로 구성된다. **Region 1(공유 전단부)**은 28×28 입력을 1 pixel/cycle 로 스트리밍하여 Conv1(5×5, 3 채널)과 MaxPool 을 수행한다. 풀링 출력(12×12×3)은 Feature Map Buffer 와 Early Classifier 에 동시에 공급된다. **Region 2(난이도 판단 및 제어)**는 Early Classifier(AvgPool 3×3 → FC 48→10) 점수에서 Score Margin 을 계산하고 두 임계값과 비교해 모드를 결정한다. **Region 3(후단부)**는 Medium 또는 Hard 일 때만 버퍼를 재생(replay)하여 Conv2 와 Light/Full FC 를 수행한다. **Easy 입력은 Early 점수로 결과를 출력하므로 Conv2 와 Light/Full FC 의 추론 연산을 생략한다**(Early FC 는 수행하며, 클럭이 공급되는 레지스터의 전력은 남는다).



[그림 2] AdaPath-NPU 의 데이터 및 제어 흐름 (모델 A 의 선정 동작점에서는 Medium 미선택)

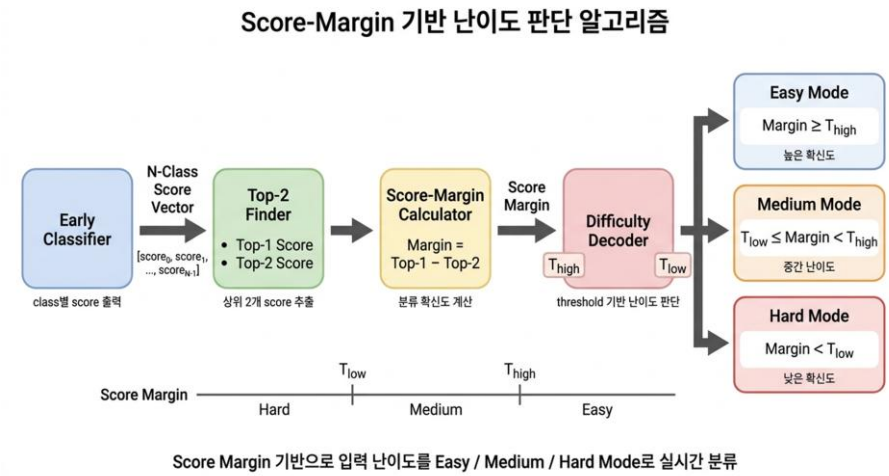
[표 4] 모드별 활성 경로와 연산량 (MNIST, 10 개 클래스)

모드	활성 경로	MAC (A)	MAC (B)
Easy	Conv1 + Early Classifier	43,680	43,680
Medium	Conv1 + Early Classifier + Conv2 일부 채널 + Light FC	48,640	63,520
Hard	Conv1 + Early Classifier + Conv2 전 채널 + Full FC	58,560	83,360
Baseline (항상 Hard)	Conv1 + Conv2 전 채널 + Full FC (Early Classifier 없음)	58,080	82,880
Reference	Conv1 + Conv2 + FC (항상)	58,080	-

A: Conv2 3 채널, Medium 1 채널. B: Conv2 8 채널, Medium 4 채널. 모드별 MAC 에는 Early FC(480 MAC)가 포함된다.

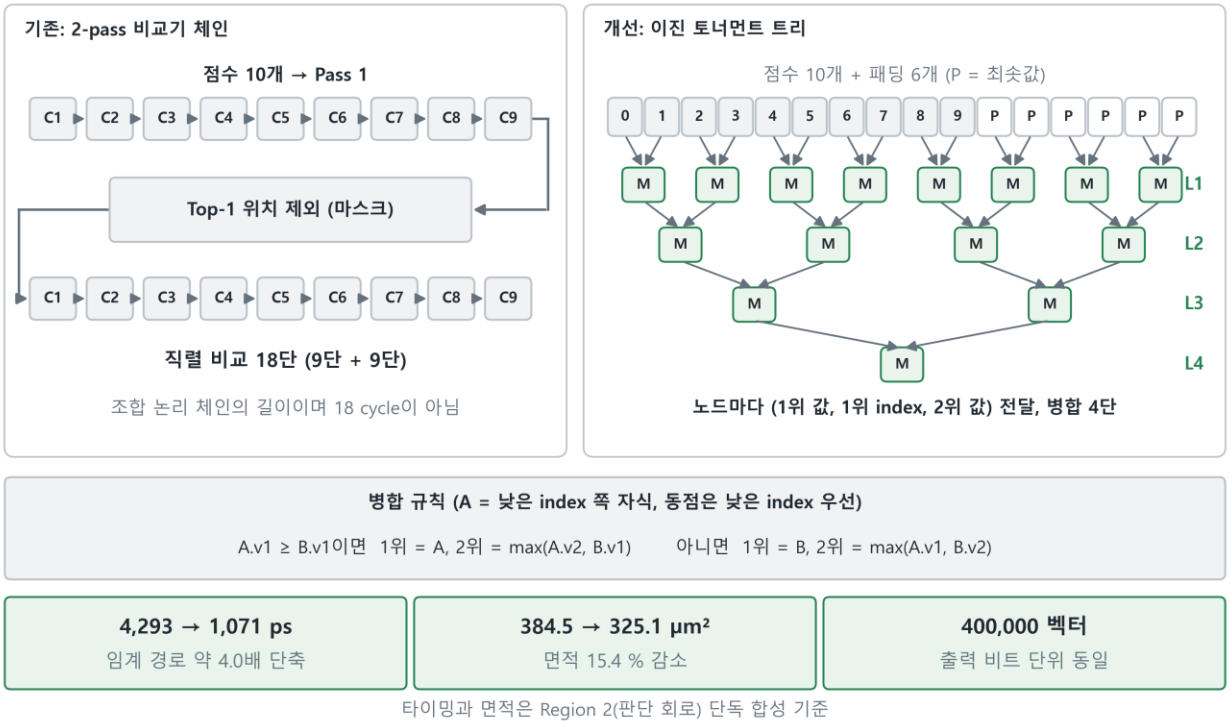
3.2 Score Margin 기반 난이도 판단과 Top-2 Finder 개선

Score Margin m = s(Top-1) − s(Top-2)는 분류기가 1 순위를 얼마나 확신하는지를 나타낸다. m ≥ T_high 이면 Easy, T_low ≤ m < T_high 이면 Medium, m < T_low 이면 Hard 로 판정한다. **RTL 시뮬레이션에서는 X 비교의 if/else 처리에 따라 Hard 로 진행할 수 있으나**, 합성 넷리스트의 X 전파 차단이나 실제 회로의 안전 동작을 보증하지 않는다.



[그림 3] 난이도 판단 및 모드 결정 흐름

10 개 점수의 Top-2 를 구하는 기존 회로는 Top-1 탐색(Pass 1, 9 단)과 해당 위치를 제외한 Top-2 탐색(Pass 2, 9 단)을 직렬로 연결하여 최대 18 개의 비교 단계가 형성되었고, 이 경로가 설계 전체의 임계 경로가 되었다. 이를 **이진 토너먼트 트리**로 재설계하였다(그림 4). 10 개 점수와 6 개 패딩 잎을 4 개의 병합 레벨로 축약하며, 각 노드는 (1 위 값, 1 위 index, 2 위 값)을 전달한다. 두 자식 A(낮은 index), B 의 병합 규칙은 A.v1 ≥ B.v1 이면 1 위=A, 2 위=max(A.v2, B.v1), 아니면 1 위=B, 2 위=max(A.v1, B.v2)이다. 동점이면 낮은 index 가 이기므로 기존 회로와 출력이 같다. 4 레벨은 트리의 구조적 깊이이며 4 cycle 이나 표준셀 4 단을 뜻하지 않는다. **출력 레지스터는 1 단 그대로이므로 처리 cycle 은 변하지 않는다**.



[그림 4] Top-2 Finder: 직렬 비교 체인에서 이진 토너먼트 트리로

[표 5] Top-2 구조 개선에 따른 판단 및 제어 회로 단독 합성 결과 (Top-2, Margin, Decoder, FSM; Early Classifier 제외)

항목	기존 (비교기 체인)	개선 (토너먼트 트리)	변화
임계 경로	4,293 ps	1,071 ps	약 4.01 배 단축
면적	384.5 μm²	325.1 μm²	15.4 % 감소
기능 동일성	-	테스트한 400,000 벡터에서 출력 비트 동일	-

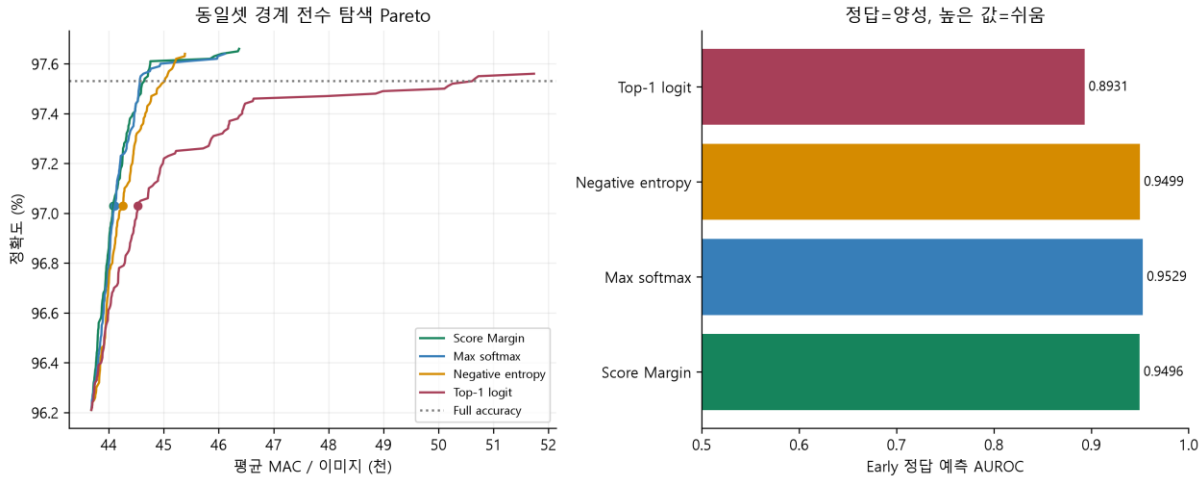
400,000 벡터는 무작위, 동점 다수, 경계값(최소/최대), 전부 동일 값을 포함한 테스트 결과이며, 전체 입력 공간에 대한 형식적 동등성 증명은 아니다.

난이도 지표 비교: Score Margin 을 선택한 근거를 확인하기 위해, 같은 Early Classifier 로짓으로 Score Margin, 최대 softmax 확률, 엔트로피, Top-1 로짓을 비교하였다(모델 A, MNIST 10,000 장, Python float 분석, 그림 5). Full 대비 정확도 손실 0.5 %p 제약에서 Score Margin 은 네 지표 중 가장 작은 평균 MAC(44,079)을 보였으나 다른 지표와의 차이는 0.06~1.0 %로 작았고, Early 정답 여부를 구분하는 AUROC 는 최대 softmax 확률(0.953)이 Score Margin(0.950)보다 약간 높았다. Score Margin 은 확률 정규화와 exp, log 같은 비선형 연산 없이 비교와 감산으로 구현된다는 이점이 있지만, Top-1 로짓보다 연산이 적은 것은 아니므로 '네 지표 중 최소 회로 비용'이라고 결론짓지 않는다. 즉 **Score Margin 은 비선형 연산 없이 유리한 정확도–연산량 절충을 보인 지표로 해석한다**(지표별 면적 및 지연은 측정하지 않음).

[표 6] 난이도 지표 비교 (모델 A, Full 대비 정확도 손실 0.5 %p 제약, 동일셋 탐색)

지표	필요 연산 (직접 계산 기준)	AUROC	정확도	평균 MAC	Hard 대비 MAC 절감
Score Margin	비교 트리 + 감산 1 (exp/log/나눗셈 없음)	0.950	97.03 %	44,079	24.73 %
최대 softmax 확률	exp 10, 덧셈 9, 정규화(나눗셈) + 최대값	0.953	97.03 %	44,106	24.68 %
엔트로피	softmax + log 10, 곱셈 10, 덧셈 9	0.950	97.03 %	44,256	24.43 %
Top-1 로짓	비교 9 (최대값만)	0.893	97.03 %	44,530	23.96 %

연산 수는 직접 수식 기준이며 합성 후 셀 수, 면적, 지연이 아니다. 판정만 필요하면 최대값 정규화 등으로 비선형 연산을 줄일 수 있다. 같은 테스트셋에서 탐색한 결과로 낙관 편향이 있을 수 있으며, 2-fold 교차 평가 평균 정확도는 Margin 97.02 %, 최대 softmax 96.99 %, 엔트로피 96.98 %, Top-1 97.00 %였다.



[그림 5] 모델 A 의 네 난이도 지표에 대한 동일셋 정확도–MAC Pareto 와 Early 정답 예측 AUROC

3.3 소프트웨어 모델링, 임계값 탐색, 정수 양자화

세 출력(Early / Light / Full)을 가진 3-head 모델을 MNIST 학습셋 60,000 장으로 공동 학습하였다(표 7). 이후 테스트셋에서 (T_low, T_high)를 탐색하여 **'Full 경로 대비 정확도 손실 0.5 %p 이내에서 평균 MAC 최소'인 동작점을 선택하였다**. 0.5 %p 는 주최 측 기준이 아니라 본 팀이 정한 내부 선정 규칙이다. 이 동작점은 테스트셋 기반 탐색 결과이므로, 임계값 선정과 평가를 분리한 교차 평가를 아래에 함께 제시한다. 정수 규약은 가중치 INT8, 활성값과 점수 인터페이스 signed 12-bit(포화), bias 누산기 도메인 16-bit, 재양자화 반올림 시프트이며, 이 규약으로 RTL 과 비트 단위로 일치하는 Golden 모델을 생성하였다.

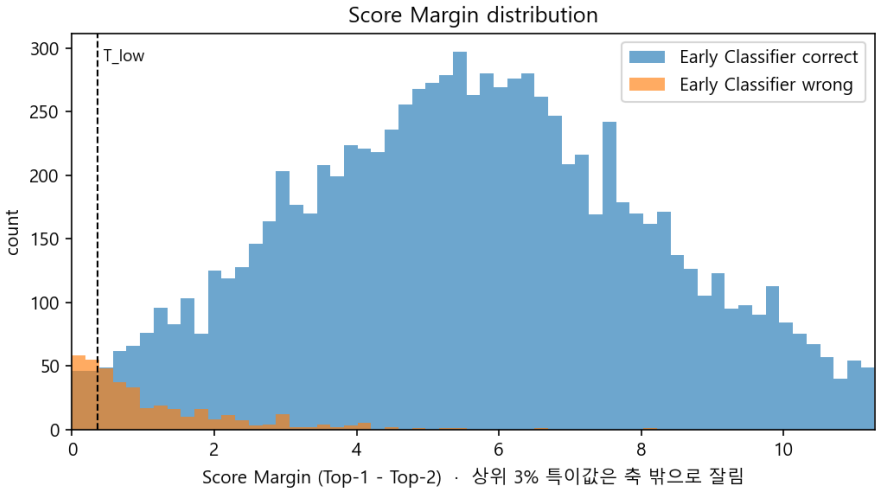
[표 7] 학습 설정 (모델 A 와 B, MNIST / WM-811K 공통)

항목	설정	항목	설정
Optimizer	Adam, lr 2×10^{-3}	Scheduler	Cosine annealing
Epoch / Batch	30 / 128	손실	CE(Full) + 0.5×CE(Early) + 0.5×CE(Light)
입력	28×28, [0,1] 정규화	Random seed	seed 미고정; 반복 재학습 변동성 미평가

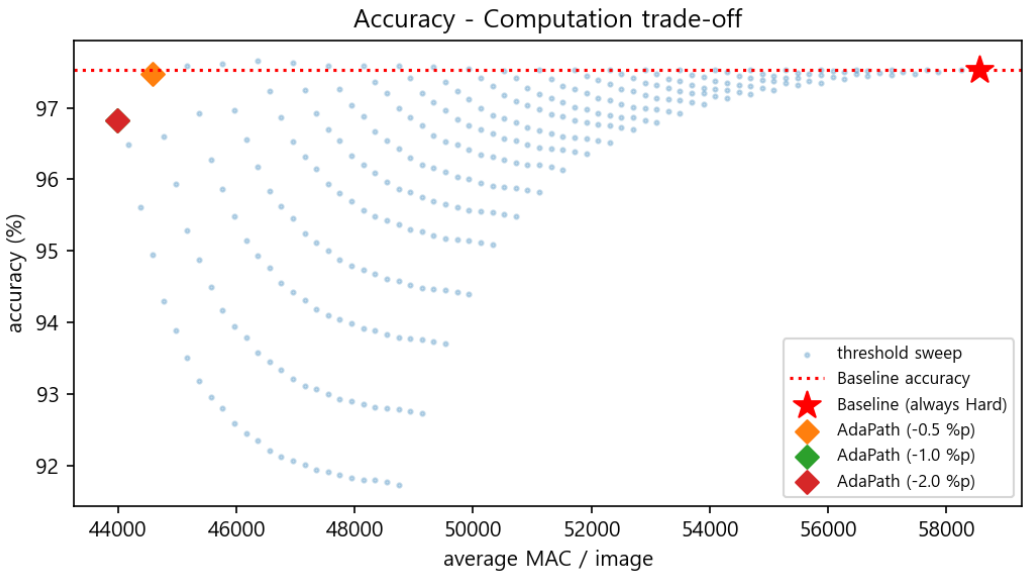
[표 8] 모델별 정확도와 선정 동작점 (MNIST 테스트셋 10,000 장)

항목	모델 A (지정주제)	모델 B (확장)
Full / Light / Early 정확도 (float)	97.53 / 91.14 / 96.21 %	98.51 / 97.76 / 95.18 %
선정 동작점 모드 비율 (Easy / Medium / Hard)	94.0 / 0 / 6.0 %	82 / 8 / 10 %
AdaPath 정확도 / 평균 MAC 절감	97.47 % / 23.9 %	98.12 % / 40.9 %
정수 Hard 경로 정확도 (같은 표본의 float 대비)	97.10 % (float 96.80 %, n=1,000)	97.80 % (float 97.95 %, n=2,000)

모델 A 는 Conv2 가 3 채널뿐이어서 1 채널 Light 경로의 정확도(91.14 %)가 낮다. 임계값 탐색은 Medium 구간을 두지 않는 동작점(T_low = T_high)을 평가한 후보 중에서 선택하였고, 그 결과 **모델 A 는 Easy/Hard 두 경로로 동작한다**. 반면 후단부가 큰 모델 B 와 WM-811K 에서는 Medium 이 선택된다(3.8 절).



[그림 6] 모델 A 의 Score Margin 분포와 선정 임계값



[그림 7] 모델 A 의 임계값 조합별 정확도와 평균 MAC (MNIST 테스트셋, Python float). 점은 탐색한 (T_low, T_high) 조합, 별은 항상 Hard 인 Baseline 이다.

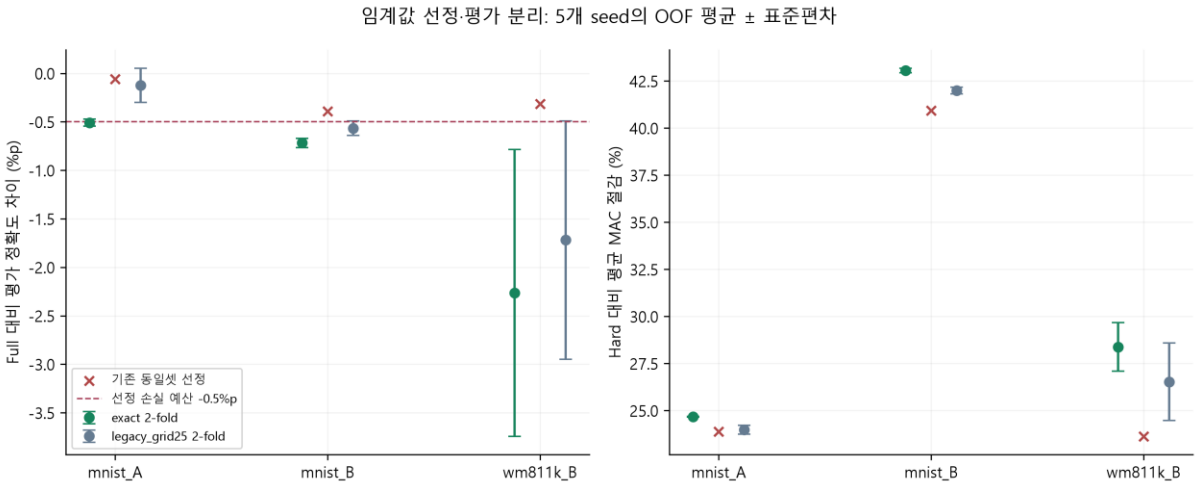
3.3.1 임계값 선정과 평가의 분리 (2-fold 교차 평가)

임계값 선정과 평가에 같은 데이터를 쓰는 문제를 줄이기 위해, 고정 가중치 모델에 대해 테스트셋을 무작위로 반분하여 한쪽에서 동작점을 선정하고 다른 쪽에서 평가하는 2-fold 교차 평가를 5 개 분할 seed 로 반복하였다(표 9, 그림 8). 기존 보고점과 같은 25 개 분위수 후보로 선정하면 모델 A 는 두 평가 절반을 합친 반복별 결과에서 정확도 97.41 ± 0.18 %, MAC 절감 23.99 ± 0.23 %로 5 회 모두 0.5 %p 손실 예산을 지켰다. 반면 더 촘촘한 경계 전수 탐색에서는 모델 A 도 5 회 중 3 회 예산을 넘었고(손실 0.51 ± 0.04 %p), 모델 B 와 WM-811K 는 두 탐색법 모두 5 회 전부 예산을 넘었다(WM 손실 2.26 ± 1.48 %p). 즉 **선정 데이터에서 지킨 정확도 제약이 미사용 데이터에서 보장되지는 않으며**, 특히 표본이 작고 클래스가 어려운 WM-811K 에서 차이가 컸다. 이 분석은 이미 관찰된 테스트셋을 사후 분할한 것으로, 새로운 외부 테스트셋 검증은 아니다(표준편차는 분할 seed 에 따른 변동).

[표 9] 임계값 선정 및 평가 분리 결과 (2-fold × 5 분할 seed, 평가 절반 기준, Python float)

모델	탐색	정확도 (%)	Full 대비 손실 (%p)	Hard 대비 MAC 절감 (%)	Easy / Medium / Hard (%)	예산 초과
MNIST A	기존 보고점 (동일셋)	97.47	0.06	23.89	94.0 / 0 / 6.0	-
MNIST A	25 분위수 후보	97.41 ± 0.18	0.12	23.99 ± 0.23	94.4 / 0 / 5.6	0 / 5
MNIST A	경계 전수 탐색	97.02 ± 0.04	0.51	24.68 ± 0.02	97.1 / 0 / 2.9	3 / 5
MNIST B	기존 보고점 (동일셋)	98.12	0.39	40.94	82.0 / 8.0 / 10.0	-
MNIST B	경계 전수 탐색	97.79 ± 0.05	0.72	43.06 ± 0.12	85.9 / 9.2 / 4.9	5 / 5
WM-811K	기존 보고점 (동일셋)	81.24	0.31	23.64	42.0 / 15.9 / 42.0	-
WM-811K	경계 전수 탐색	79.29 ± 1.48	2.26	28.38 ± 1.30	55.5 / 9.1 / 35.4	5 / 5

선정 규칙: 선정 절반에서 Full 대비 정확도 손실 0.5 %p 이내의 최소 MAC. 평가 절반에서는 제약을 강제하지 않는다. 각 반복의 두 평가 절반을 합친 OOF 결과를 요약하였으며, MAC 절감의 분모는 Hard 경로(Early FC 포함)이다.



[그림 8] 임계값 선정 및 평가를 분리한 2-fold 결과 (5 개 분할 seed 의 평균 ± 표준편차, × = 기존 동일셋 동작점)

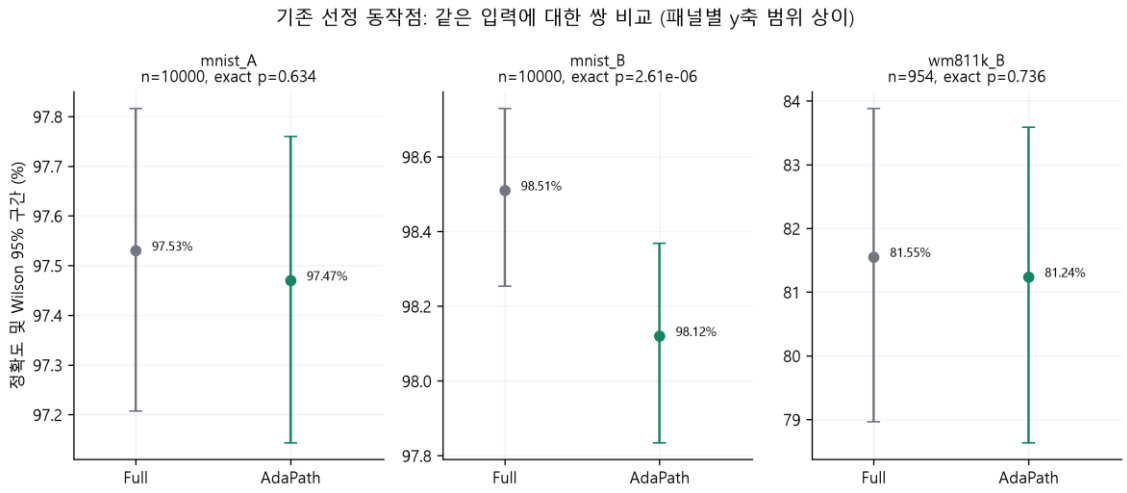
3.3.2 통계적 비교

기존 동작점에서 AdaPath 와 같은 체크포인트의 Full 경로를 같은 이미지 쌍으로 비교하였다(표 10). 모델 A 는 97.47 % vs 97.53 % (Wilson 95 % 구간 97.14–97.76 % vs 97.21–97.82 %)이고, 불일치 쌍은 Full 만 정답 58 장, AdaPath 만 정답 52 장으로 **McNemar exact p = 0.63** 이었다. 모델 B 는 Full 만 정답인 쌍이 54 장 대 15 장으로 유의한 정확도 하락($p = 2.6\times10^{-6}$)이 있었으며, 이는 B 의 동작점이 0.39 %p 손실을 수용한 결과와 일치한다. 즉 **모델 A 와 WM-811K 에서는 적응형 경로가 Full 경로와 통계적으로 구별되는 정확도 손실을 만들지 않았다**.

[표 10] 기존 동작점의 AdaPath vs Full 통계 비교 (같은 체크포인트, 이미지 단위)

모델	n	AdaPath (95 % CI)	Full (95 % CI)	b / c	McNemar p (Holm)
MNIST A	10,000	97.47 % (97.14–97.76)	97.53 % (97.21–97.82)	58 / 52	0.634 (1.0)
MNIST B	10,000	98.12 % (97.83–98.37)	98.51 % (98.25–98.73)	54 / 15	2.6×10^{-6} (7.8×10^{-6})
WM-811K	954	81.24 % (78.64–83.59)	81.55 % (78.97–83.88)	19 / 16	0.736 (1.0)

b = Full 만 정답, c = AdaPath 만 정답. 양측 exact 검정, 세 비교에 Holm 보정.

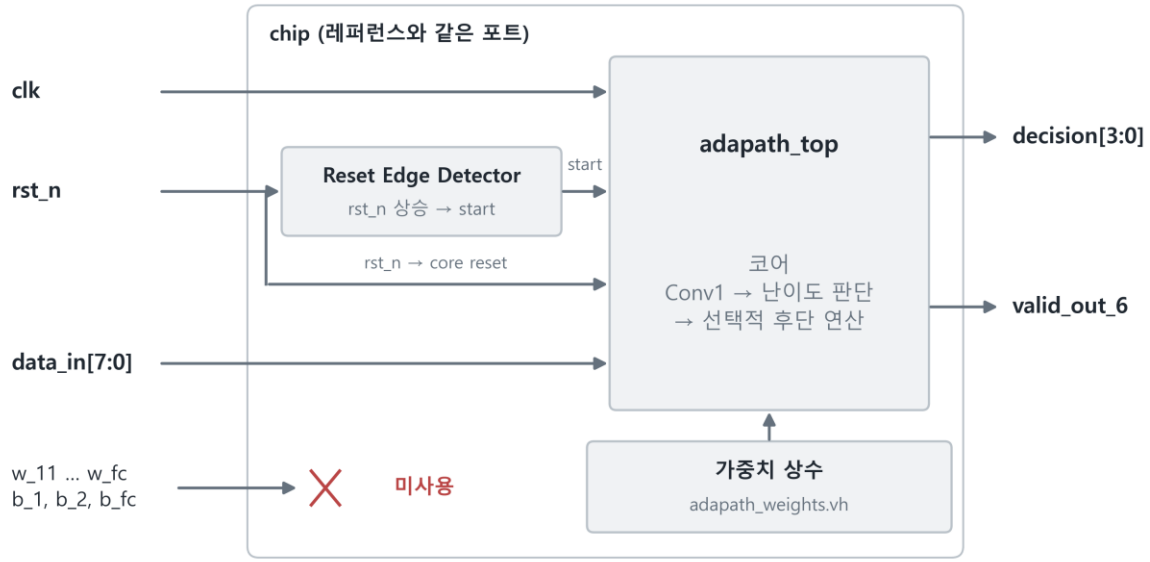


[그림 9] 기존 동작점에서 같은 이미지 쌍의 Full 과 AdaPath 정확도 (Wilson 95 % 구간, 패널별 y 축 범위가 다름)

3.4 RTL 설계와 주최 측 인터페이스 호환

RTL 은 채널 수 및 클래스 수를 파라미터화한 **단일 소스(adapath_top.v)로 작성하였다**. VARIANT(0: Baseline, 1: Early-Exit, 2: AdaPath)와 C2/C2_MED(모델 A 와 B), N_CLASS(MNIST 10, WM-811K 4) 및 각 모델의 가중치, 임계값, shift 설정만 바꿔 표 2 의 비교 설계를 생성하였다. 주요 블록은 conv1_engine(75 MAC 병렬), fmap_buffer(144×36 bit), early_classifier, top2_finder, score_margin_calc, difficulty_decoder, mode_control_fsm, conv2_engine(채널 enable), fc_engine(Light/Full)이다.

주최 측 평가는 제출 프로젝트의 테스트벤치에서 입력 파일만 교체하는 방식이므로, 레퍼런스 chip 과 **포트 목록 및 폭이 같은 래퍼(chip_adapath.v)**를 제작하였다(그림 10). 레퍼런스 가중치 포트는 호환용으로 입력만 받고 사용하지 않으며, **본 팀이 학습한 가중치는 래퍼 내부 상수(adapath_weights.vh)로 고정**하였다. 레퍼런스는 rst_n 해제 직후부터 픽셀을 받으므로, clk 로 샘플링한 rst_n 의 상승을 검출하여 코어의 start 펄스를 생성한다(reset low 구간이 최소 1 clk 이상 관측되어야 함). **주최 측 top_tb.v 는 테스트벤치 로직을 수정하지 않았으며**, 데이터 파일 경로만 프로젝트 내부 파일명으로 지정하였다. 시뮬레이션 top 은 top_tb_1000, 도구는 Vivado 2023.1 이다.



[그림 10] 주최 측 chip 인터페이스를 유지하는 래퍼

3.5 기능 검증

[표 11] 기능 검증 결과

검증 단계	방법	결과
판단 및 제어 회로 단위	Python Golden 200 벡터	200 / 200 일치
Top-2 Finder 개선	기존 회로와 400,000 벡터 비교 (무작위, 동점, 경계값)	테스트 벡터 전부 출력 동일
End-to-end	3 종 구조 × 9 장, 모드별 대표 이미지	27 / 27 Golden 일치
1,000 장 회귀 (모델 B)	MNIST 1,000 장 Golden (margin / mode / decision)	1,000 / 1,000 일치
게이트레벨 (A, B, Reference)	합성 넷리스트 + ASAP7 셀 모델 시뮬레이션	RTL 과 판정, 모드, cycle 동일
주최 측 TB (Vivado 2023.1)	top_tb_1000, 테스트벤치 로직 무수정	Reference 96.7 % / A 96.6 % / B 99.9 %
WM-811K (Vivado 2023.1)	chip 래퍼(4 개 클래스) + tb_wm, 테스트 954 장	Golden 판정, 모드, Margin 954 / 954 일치
합성 넷리스트 (Vivado 2023.1)	ORFS 넷리스트 + ASAP7 셀 + 원본 TB + xfill, 5 개 시드 부분 실행	판정 1,007/1,007, cycle 1,006/1,006 일치

[표 12] 주최 측 입력(input_1000.txt) 기준 정확도와 처리 cycle

설계	정답 (순차 입력)	정답률 (주최 TB)	평균 cycle (주최 TB)	평균 cycle (순차 입력)	모드 분포 (순차)
Reference	970 / 1,000	96.7 %	1,336	1,334	-
Baseline_A	970 / 1,000	-	-	985	0 / 0 / 1,000
AdaPath_A	**970 / 1,000**	96.6 %	854.8	**851.8**	960 / 0 / 40
AdaPath_B	1,000 / 1,000	99.9 %	870.3	867.2	870 / 60 / 70

input_1000.txt 는 고유 100 장이 10 회 반복된 1,000 회 입력이다. '순차 입력'은 1,000 회를 순서대로 처리한 결과이고, '주최 TB'는 원본 TB 의 무작위 추출 실행 결과이다. cycle 은 start(rst_n 해제)부터 valid_out 까지이다.

3.5.1 주최 측 TB 의 입력 경계

원본 TB 는 $urandom_range(0,1000)으로 이미지 인덱스를 뽑으므로 인덱스 1000 이 선택되면 범위 밖 X 픽셀을 읽고(Vivado 2024.1 의 Reference 실행에서 3 회), 첫 출력 1 회는 state 가 X 인 비채점 출력이다. 이 영향(최대 0.3 %p)을 배제하기 위해 정확도와 cycle 비교의 주 근거는 1,000 회 순차 실행(970 / 1,000)으로 하였다.

3.5.2 별도 수정 TB 재검증

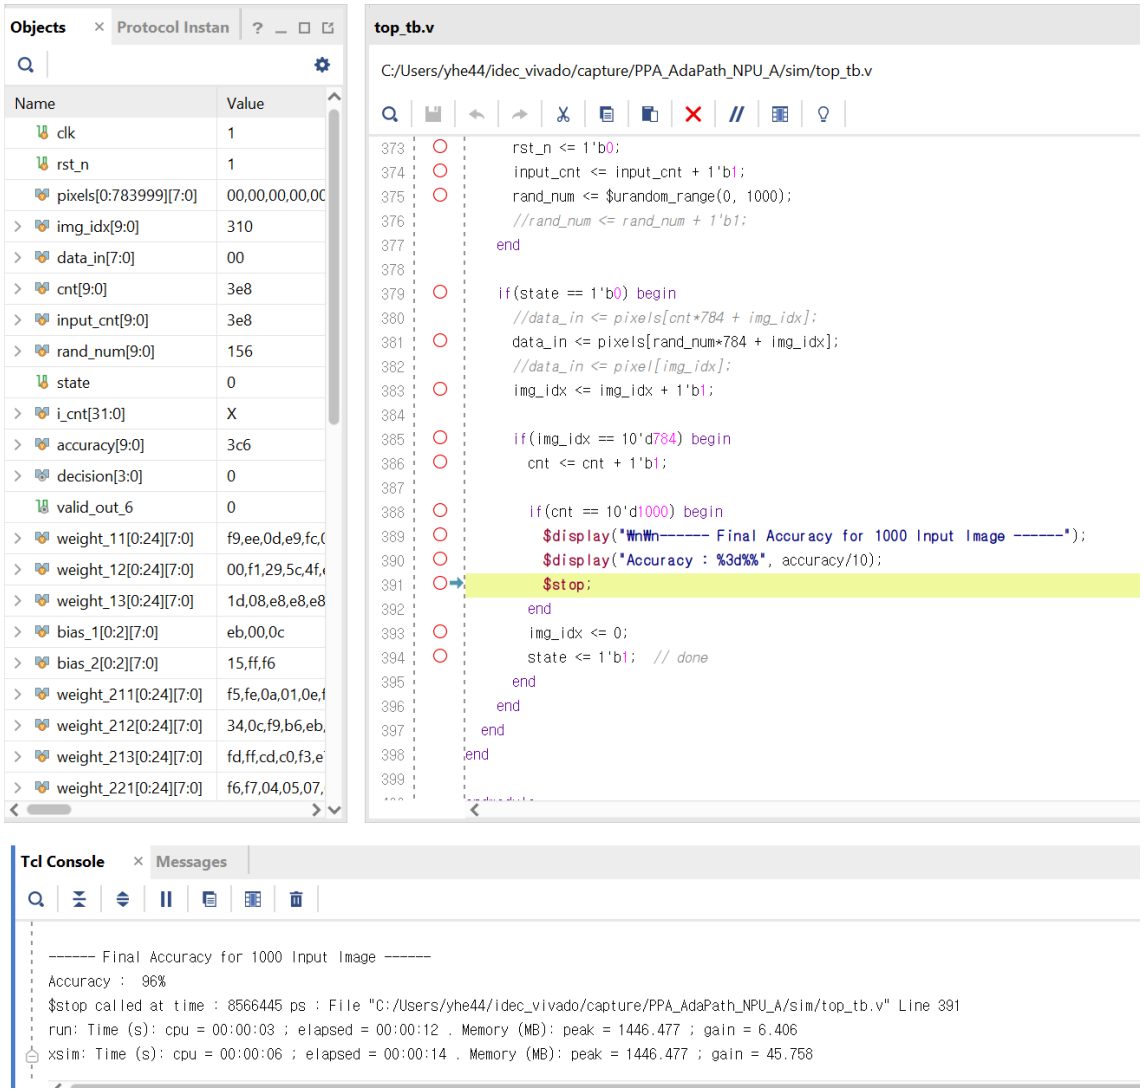
입력 경계를 보완한 별도 TB(top_tb_1000_corrected.v)로 같은 chip 래퍼를 재검증하였다. 상태와 입력을 초기화하고 인덱스를 0~999 로 제한하여 순차 1,000 회와 무작위(seed 2026) 1,000 회를 실행하였다.

[표 13] 별도 수정 TB 의 입력 및 출력 무결성 재검증 (모델 A)

검사 항목	순차 1,000 회	무작위 1,000 회
유효 출력 수	1000	1000
정답 수	970	971
Easy / Medium / Hard	960 / 0 / 40	956 / 0 / 44
범위 밖 읽기	0	0
X 데이터 읽기	0	0
X 출력	0	0
픽셀 읽기 수	784000	784000

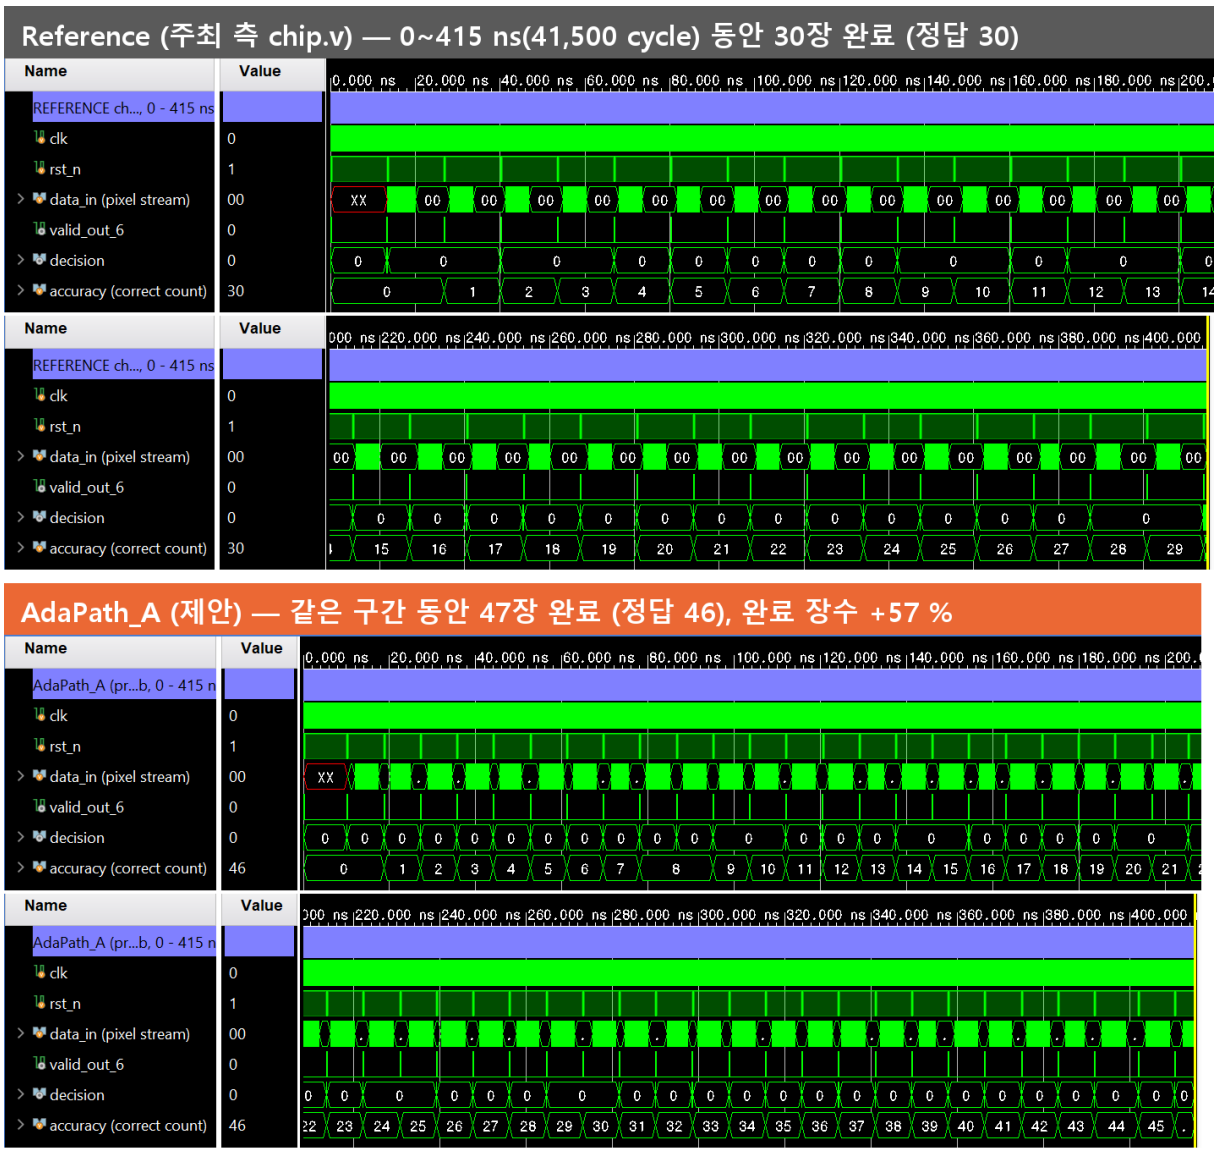
두 실행 모두 범위 밖 읽기와 X 출력 없이 1,000 개 출력을 4,000 cycle 이내에 완료하였고, **무작위 실행의 판정과 모드는 같은 인덱스의 순차 실행 결과와 1,000 / 1,000 일치**하였다.

3.5.3 Vivado 실행 화면과 파형



[그림 11] Vivado 2023.1 실행 화면 — 주최 측 top_tb_1000 실행 결과 (AdaPath_A)

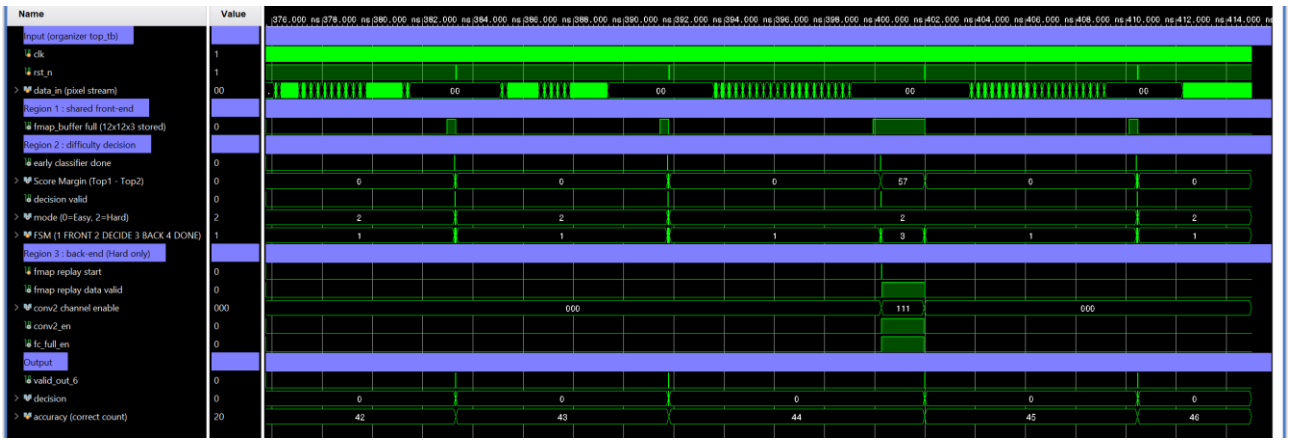
제출 프로젝트(.xpr)를 Vivado 2023.1 에서 그대로 실행한 화면이다. 원본 테스트벤치의 cnt 가 1,000 에 도달한 뒤 $stop(391 행)에서 정지하였고, Tcl 콘솔에 **'Accuracy : 96%'가 출력되었다**. Objects 창의 accuracy = 0x3C6(966), cnt = 0x3E8(1,000)이다.



[그림 12] 같은 41,500 cycle(0~415 ns, 논리 시뮬레이션) 동안 완료한 이미지 수: Reference 30 장 vs AdaPath_A 47 장 (각 설계의 파형을 0~207 ns 와 207~415 ns 두 줄로 표시)

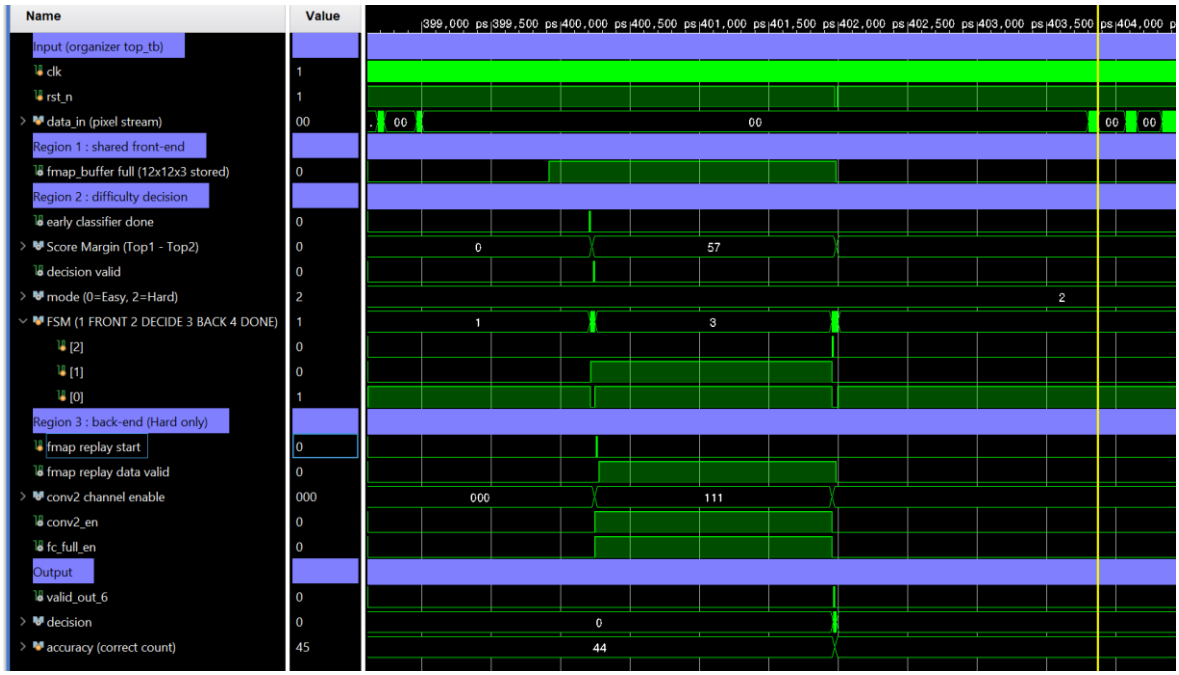
같은 테스트벤치에서 같은 41,500 cycle 동안 Reference 는 30 장(정답 30), **AdaPath_A 는 47 장(정답 46)을 완료하여 57 % 많은 이미지를 처리**하였다. 이미지당 평균 처리 cycle 이 1,336 에서 855 로 줄어든 효과가 파형에 그대로 나타난다.

파형의 시간축은 원본 TB 의 10 ps 클럭에 따른 기능 시뮬레이션 시간이며, 물리적 동작 주파수는 3.6 절의 STA 결과를 따른다.



[그림 13] Vivado 파형 (376~415 ns, 논리 시뮬레이션): 실행 순번 42~45 번째(Easy)와 46 번째(Hard) 이미지의 내부 동작 비교

실행 순번 42~45 번째 Easy 이미지는 Early Classifier 가 끝난 직후 FSM 이 FRONT(1)에서 바로 출력으로 넘어가므로, **Feature Map Buffer 재생, Conv2 채널 enable, Full FC 가 활성화되지 않는다**. 46 번째 이미지만 Score Margin 이 57 로 임계값 63 보다 작아 Hard 로 판정되며 후단부가 동작한다. mode 및 margin 레지스터는 이미지마다 리셋되고 Easy 판정은 출력 직전 수 cycle 동안만 유지되므로, 이 배율에서는 리셋값(Hard=2)이 주로 보인다.



[그림 14] Vivado 파형 확대 (399~404 ns, 논리 시뮬레이션): 46 번째(Hard 판정) 이미지의 내부 처리 순서

Hard 판정 시 내부 동작은 ① Early Classifier 완료 → ② Score Margin 57 산출 및 판정 유효 → ③ FSM BACK(3) 전환 → ④ Feature Map Buffer 재생 시작 및 재생 데이터 유효 구간 → ⑤ Conv2 전 채널 enable(111)과 Full FC 동작 → ⑥ valid_out_6 출력과 누적 정답 수 증가(44 → 45) 순서로 진행된다. **Hard 이미지 1 장의 추가 처리 시간은 Easy 대비 171 cycle 이다**.

3.5.4 제출 패키지의 독립 PC 재현 (Vivado 2024.1)

제출 패키지의 이식성을 확인하기 위해 작성자와 다른 PC 의 Vivado 2024.1 에서 A, B, WM 프로젝트 ZIP 을 새 경로에 풀어 실행하였다. 패키지 파일의 SHA-256 이 원본과 일치하였고, **A 966 / 1,000, B 999 / 1,000, WM 774 / 954(81.13 %)와 Golden 954 / 954 일치를 그대로 재현**하였다. WM 의 Easy / Medium / Hard 사용 횟수도 404 / 167 / 383 으로 같았다.

(a) 지정주제 AdaPath_A: 정답 966 / 1,000

```
1000th input image : original value = 2, decision = 7 at 8556365 ps ==> Fail


------ Final Accuracy for 1000 input image ------
Accuracy :  966
$stop called at time : 8566445 ps : File "C:/Temp/ppa_final_verify_20261030/PPA_AdaPath_NPU_A/sim/top_tb.v" Line 391
run: Time (s): cpu = 00:00:20 ; elapsed = 00:00:36 . Memory (MB): peak = 1574.709 ; gain = 0.531
xsim: Time (s): cpu = 00:00:34 ; elapsed = 00:00:43 . Memory (MB): peak = 1574.709 ; gain = 24.004
INFO: [USF-XSim-96] XSim completed. Design snapshot 'top_tb_1000_behav' loaded.
INFO: [USF-XSim-97] XSim simulation ran for all
launch_simulation: Time (s): cpu = 00:00:40 ; elapsed = 00:01:00 . Memory (MB): peak = 1574.709 ; gain = 24.004
# puts "SUBMIT_CHECK_END model=A"
SUBMIT_CHECK_END model=A
# puts "CHECK accuracy_dec=[get_value -radix unsigned /top_tb_1000/accuracy] accuracy_hex=[get_value -radix hex /top_tb_1000/
CHECK accuracy_dec=966 accuracy_hex=3c6 cnt=1000
```

(b) 확장 모델 AdaPath_B: 정답 999 / 1,000

```
1000th input image : original value = 2, decision = 2 at 8712405 ps ==> Success


------ Final Accuracy for 1000 input image ------
Accuracy :  999
$stop called at time : 8720345 ps : File "C:/Temp/ppa_final_verify_20261030/PPA_AdaPath_NPU_B/sim/top_tb.v" Line 391
run: Time (s): cpu = 00:00:21 ; elapsed = 00:00:39 . Memory (MB): peak = 1570.473 ; gain = 1.426
xsim: Time (s): cpu = 00:00:36 ; elapsed = 00:00:47 . Memory (MB): peak = 1570.473 ; gain = 45.215
INFO: [USF-XSim-96] XSim completed. Design snapshot 'top_tb_1000_behav' loaded.
INFO: [USF-XSim-97] XSim simulation ran for all
launch_simulation: Time (s): cpu = 00:00:47 ; elapsed = 00:01:08 . Memory (MB): peak = 1570.473 ; gain = 64.660
# puts "SUBMIT_CHECK_END model=B"
SUBMIT_CHECK_END model=B
# puts "CHECK accuracy_dec=[get_value -radix unsigned /top_tb_1000/accuracy] accuracy_hex=[get_value -radix hex /top_tb_
CHECK accuracy_dec=999 accuracy_hex=3e7 cnt=1000
```

(c) 자유주제 AdaPath_WM: 774 / 954 (81.13 %), Golden 954 / 954

```
      Final Accuracy for 954 WM 811K Test Images
Accuracy : 774 / 954 = 81.13 %
Golden match (decision)              : 954 / 954
Golden match (decision, mode, margin): 954 / 954
Mode Easy / Medium / Hard            : 404 / 167 / 383
Class 0 recall : 179 / 245
Class 1 recall : 238 / 251
Class 2 recall : 216 / 230
Class 3 recall : 141 / 228
```

[그림 15] 독립 PC 의 Vivado 2024.1 에서 제출 ZIP 3 종을 실행한 Tcl 콘솔 (콘솔의 백분율은 원본 TB 의 정수 나눗셈 표시)

3.5.5 제어 조건 검사

Vivado 2024.1 에서 RTL 과 TB 를 변경하지 않고 읽기 전용 관측 모듈을 시뮬레이션 최상위에 추가하여, 4 개 제어 조건을 매 cycle 검사하였다(표 14).

[표 14] 제어 조건의 동적 검사 (Vivado 2024.1, 검사 횟수 / 위반 건수)

검사 조건 및 단위	모델 A	WM-811K
Easy 결정 후 valid 까지 Conv2 비활성 (cycle)	1,920 / 0	808 / 0
Medium 후단 활성 중 채널 mask, Light/Full FC 선택 (cycle)	0 / 해당 없음	27,555 / 0
start→valid 4,000 cycle 이내 응답 (완료 거래)	1,001 / 0	954 / 0
S_BACK 과 S_DONE 에서 선택 모드와 Result MUX 일치 (cycle)	8,012 / 0	91,704 / 0

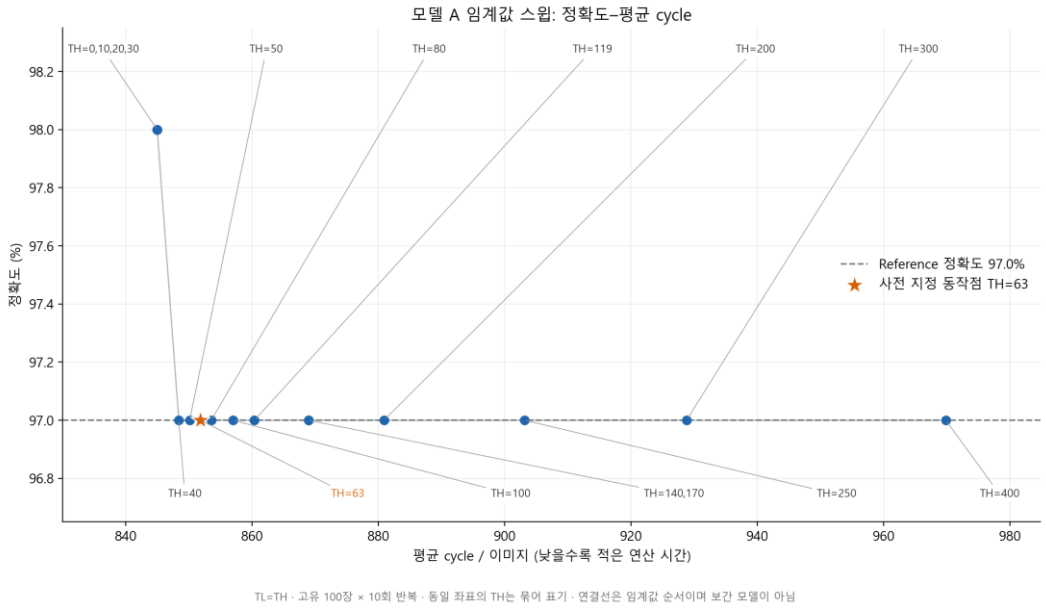
모델 A 는 선정 동작점에서 Medium 을 사용하지 않는다. WM 은 Medium 167 장의 후단 활성 27,555 cycle 을 검사하였다.

모든 조건에서 위반은 0 건이었고, 검사한 제어 신호에서 X 는 관측되지 않았다. 관측 모듈은 4 종 위반을 인위로 주입한 자가 시험에서 각 위반을 검출함을 확인하였다. A 의 채점 로그 1,000 개는 기존 ZIP 실행과 줄 단위로 같았다(정답 966).

3.5.6 런타임 임계값 스윕 (RTL 실측)

difficulty_decoder 의 레지스터 임계값 모드(USE_REG_TH)를 최상위 포트로 연결하고, 주최 측 입력 1,000 회에 대해 TL = TH 를 0~400 으로 바꿔 가며 16 개 동작점을 RTL 로 측정하였다(그림 16). TH = 63 에서 기존 결과(정답 970, 평균 851.84 cycle, Easy/Hard 960/40)가 재현되었다. TH 를 높이면 Hard 수가 0(TH = 0)에서 730(TH = 400)까지 늘고 평균 cycle 은 845.0 에서 969.8 로 증가하여, **칩을 다시 합성하지 않고 런타임에 정확도–연산 시간 동작점을 바꿀 수 있음을 확인하였다**. 이 입력 집합에서는 TH = 0, 10, 20, 30(전부 Easy)이 정답 980 개로 가장 높았으나, MNIST 테스트셋 10,000 장에서는 Early 경로 단독 정확도(96.21 %)가 Full 경로(97.53 %)보다 낮다. **즉 최적 임계값은 입력 분포에 따라 달라지며, 레지스터 임계값으로 이를 칩 재설계 없이 맞출 수 있다**.

Hard 비율을 p_H 라 하면 평균 cycle 은 **$C = 845(1-p_H) + 1016p_H = 845 + 171p_H$** 이다. 16 개 조건 모두 이 관계와 일치하여, 평균 처리 cycle 을 Hard 비율로 정확히 예측할 수 있다.



[그림 16] 모델 A 런타임 임계값 스윕 (RTL 실측, 주최 측 입력 1,000 회): 정확도–평균 처리 cycle

3.5.7 합성 넷리스트의 Vivado 기능 검증

설명회 Sample Flow 의 기능 검증 단계에 따라, 제출 chip(AdaPath_A, 가중치 상수)을 ORFS 로 합성한 넷리스트와 주최 측 ASAP7 표준셀 Verilog 를 원본 top_tb_1000 과 함께 Vivado 2023.1 시뮬레이터에서 실행하고 RTL 결과와 비교하였다. 셀 모델은 지연이 0 인 기능 모델이므로 이 실행은 타이밍이 아닌 기능 일치를 확인한다.

원본 TB 는 첫 valid_out 전까지 state 가 X 이므로 첫 비채점 이미지의 픽셀을 X 로 입력하고, 인덱스 1000 이 선택될 때도 X 픽셀을 읽는다(3.5.1 절). RTL 에서는 X 가 있어도 제어가 진행되지만, 넷리스트에서는 X 가 Score Margin 과 모드 판정을 거쳐 FSM 상태 레지스터까지 전파되어 **valid_out 이 1 이 되지 않고 시뮬레이션이 시작 직후 정지**하였다. 입력에 따라 경로를 바꾸는 제어가 게이트레벨 시뮬레이션의 X 전파에 노출된 결과이며, 실제 회로의 정상 동작 또는 고장을 단정하지 않는다. 따라서 TB 파일은 수정하지 않고, **TB 가 내보내는 입력 바이트에 X 또는 Z 가 포함된 경우에만 DUT 입력을 0 으로 바꾸는 시뮬레이션 전용 모듈**을 추가하였다. 이 모듈은 각 채점 출력의 이미지 인덱스와 판정도 기록하며 DUT 의 다른 입력은 구동하지 않는다. 같은 모듈을 적용한 RTL 실행은 기존 Vivado 로그와 1,000 개 채점 출력 시각이 모두 같았고, 판정은 인덱스 1000 이미지(879 번째, 원래도 오답) 1 건만 10 에서 5 로 바뀌어 정답 수 966 은 변하지 않았다.

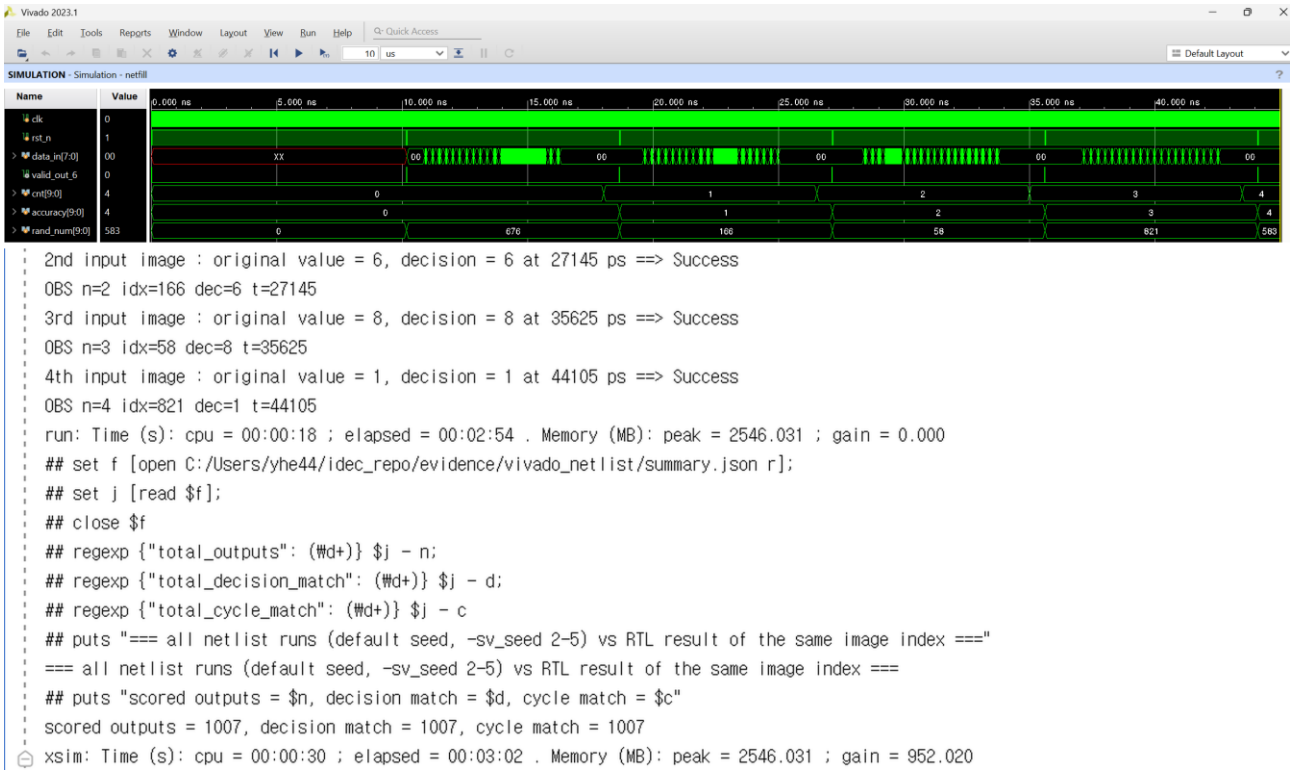
넷리스트 시뮬레이션은 RTL 보다 수백 배 느려 1,000 장 실행에 수 시간이 걸리므로, 기본 시드 실행과 함께 같은 TB 를 xsim 의 -sv_seed 2, 3, 4, 5 로 병렬 실행하였다. 출력 순서의 입력 이미지가 시드마다 다르므로, 각 출력을 같은 이미지 인덱스의 RTL 결과와 대조하였다(표 15). **합계 1,007 개 채점 출력의 판정이 RTL 과 일치**하였다. 처리 cycle 은 기준값이 있는 1,006 개 출력에서 모두

일치하였으며, 인덱스 1000 의 치환 출력 1 건은 제외하였다. 정답 수는 넷리스트와 RTL 모두 972 개였다. 출력에 포함된 입력 인덱스는 612 개이나, input_1000.txt 는 고유 이미지 100 장이 반복된 파일이므로 픽셀 내용 기준으로는 101 종(X 치환 이미지 포함)이다.

[표 15] 합성 넷리스트의 Vivado 기능 검증 결과 (Vivado 2023.1, 같은 이미지 인덱스의 RTL 결과와 대조)

실행	채점 출력 수	판정 일치	cycle 일치/대조	정답 수 (넷리스트 = RTL)
기본 시드	265	265	264/264	251
-sv_seed 2	268	268	268/268	260
-sv_seed 3	267	267	267/267	260
-sv_seed 4	198	198	198/198	192
-sv_seed 5	9	9	9/9	9
합계	**1,007**	**1,007**	**1,006/1,006**	972

기본 시드는 265 회 출력(시뮬레이션 2,280 ns)까지 확인하였다. 5 개 시드의 부분 실행 합계이며, 원본 TB 한 번의 1,000 회 실행 완료는 아니다.




```
2nd input image : original value = 6, decision = 6 at 27145 ps ==> Success
OBS n=2 idx=166 dec=6 t=27145
3rd input image : original value = 8, decision = 8 at 35625 ps ==> Success
OBS n=3 idx=58 dec=8 t=35625
4th input image : original value = 1, decision = 1 at 44105 ps ==> Success
OBS n=4 idx=821 dec=1 t=44105
run: Time (s): cpu = 00:00:18 ; elapsed = 00:02:54 . Memory (MB): peak = 2546.031 ; gain = 0.000
## set f [open C:/Users/yhe44/idec_repo/evidence/vivado_netlist/summary.json r];
## set j [read $f];
## close $f
## regexp {"total_outputs": (\d+)} $j - n;
## regexp {"total_decision_match": (\d+)} $j - d;
## regexp {"total_cycle_match": (\d+)} $j - c
## puts "=== all netlist runs (default seed, -sv_seed 2-5) vs RTL result of the same image index ==="
=== all netlist runs (default seed, -sv_seed 2-5) vs RTL result of the same image index ===
## puts "scored outputs = $n, decision match = $d, cycle match = $c"
scored outputs = 1007, decision match = 1007, cycle match = 1007
xsim: Time (s): cpu = 00:00:30 ; elapsed = 00:03:02 . Memory (MB): peak = 2546.031 ; gain = 952.020
```

[그림 17] Vivado 2023.1 시뮬레이터에서 합성 넷리스트(1_synth.v + 주최 측 ASAP7 셀 Verilog)로 원본 top_tb_1000 을 실행한 화면. 위는 처음 45 ns 의 파형, 아래 콘솔의 집계는 교정 전 값이다(cycle 대조 1 건 제외, 표 15).

그림은 같은 넷리스트 스냅샷을 GUI 모드로 다시 실행하여 캡처한 것이다. 첫 비채점 이미지 구간의 data_in 은 X 로 표시되며(0~10 ns), 그 뒤 이미지마다 rst_n 펄스와 valid_out 이 반복되고 cnt 와 accuracy 가 함께 증가한다. 콘솔의 OBS 줄은 시뮬레이션 전용 모듈이 기록한 이미지 인덱스와 판정이고, 마지막 줄은 교정 전 집계이다. 인덱스 1000 은 cycle 기준값 없이 일치로 집계되었으므로 표 15 에서 제외하였다.

처리 cycle 은 연속한 채점 출력 사이 간격에서 리셋 1 cycle 을 뺀 값으로, RTL 결과의 처리 cycle 과 같은 정의이다.

3.6 논리 합성 및 타이밍 (OpenROAD-flow-scripts, ASAP7)

모든 설계를 동일한 흐름(Yosys + ABC area 스크립트, 동일 SDC 규칙: 입출력 지연 = 클럭 주기의 20 %)으로 합성하고 OpenROAD 로 pre-layout STA 를 수행하였다. 가중치는 모든 설계에서 입력 포트로 두었다. 입력 지연이 주기에 비례하므로, 단일 주기의 WNS 로 Fmax 를 역산하지 않고 **클럭 주기를 1.0~2.4 ns 로 스윕하여 최악 slack 이 0 이 되는 주기**(인접 두 점의 선형 보간)를 추정하였다. 또한 추론 중 값이 바뀌지 않는 가중치 포트를 false path 로 둔 조건(레지스터 간, 픽셀 입력 경로 기준)의 Fmax 를 함께 제시한다.

[표 16] 합성 결과 (pre-layout, 클럭 주기 스윕)

설계	Cell Area (μm²)	Reference 대비	슬랙 0 추정 주기 (ps)	Fmax (MHz, SDC 규칙)	Fmax (MHz, 가중치 정적)
Reference	32,085	+0.0 %	1,755	569.8	674.6
Baseline_A	45,501	+41.8 %	1,841	543.3	626.7
AdaPath_A	49,858	+55.4 %	1,841	543.1	627.4
Baseline_B	74,534	+132.3 %	2,056	486.4	557.4
AdaPath_B	98,708	+207.6 %	2,019	495.4	560.6

추정 주기 및 Fmax(SDC 규칙)는 입출력 지연 20 % 조건에서 최악 slack = 0 인 교차점을 선형 보간한 값이다. 이 조건의 임계 경로는 세 설계 모두 가중치 입력 포트에서 시작한다. '가중치 정적'은 가중치 포트를 false path 로 둔 결과이다.

[표 17] STA 스윕의 실제 실패 및 통과점 (입출력 지연 20% 조건)

설계	실패 주기 (ps)	실패 slack (ps)	통과 주기 (ps)	통과 slack (ps)	통과점 주파수 (MHz)
Reference	1700	-44.03	1800	+35.97	555.6
Baseline_A	1800	-32.50	1900	+47.50	526.3
AdaPath_A	1800	-33.13	1900	+46.87	526.3

통과점 주파수는 스윕한 주기 중 STA 를 통과한 값이다.

Top-2 Finder 개선 후 AdaPath_A 의 Fmax 는 판단 회로가 없는 Baseline_A 와 두 조건 모두에서 거의 같다(SDC 규칙 543.1 vs 543.3 MHz, 가중치 정적 627.4 vs 626.7 MHz). 따라서 측정한 조건에서는 **판단 회로에 의한 뚜렷한 주파수 저하가 관측되지 않았다**. Reference 대비 SDC 규칙 기준 4.7 %, 가중치 정적 기준 7.0 % 낮은데, 이는 판단 회로가 아니라 본 팀 데이터패스(Conv2 가중치 입력 경로, FC 및 FSM 제어 경로)에서 결정된다. 판단 및 제어 회로(Top-2, Margin, Decoder, FSM) 단독 합성 면적은 325.1 μm²로, **AdaPath_A 통합 합성 면적의 0.65 %에 해당한다**(단독 합성과 통합 합성의 최적화 차이가 있어 참고치).

면적 증가의 구성: AdaPath_A 의 면적 증가(Reference 대비 17,773 μm², 55.4 % 증가)를 단계별로 나누면, **75 %는 본 팀 데이터패스에서, 25 %만 적응형 경로 추가에서 발생**하였다(표 18). 본 팀

데이터패스는 Conv1 의 75 개 MAC 을 병렬로 처리하는 스트리밍 구조로, 이 병렬 연산기가 조합 논리 면적 증가의 대부분을 차지하며 그 대가로 Baseline_A 의 처리 cycle 을 26.2 % 줄였다. 적응형 경로(Early Classifier, 판단 및 제어 회로)의 추가분은 4,357 μm²이고, 그중 판단 회로는 325.1 μm²(0.65 %)에 불과하다. 순차 소자는 세 설계 모두 전체 면적의 5~8 %로, 면적은 레지스터가 아니라 연산 병렬도가 결정한다. **면적과 추론 지연의 곱은 Reference 와 4.1 % 차이에 그쳐**, 늘어난 면적이 대부분 처리 속도로 전환되었다.

[표 18] 면적 구성과 단계별 증가분 (합성 직후, μm²)

구분	Reference	Baseline_A	AdaPath_A
조합 논리	30,311	42,229	46,122
순차 소자 (비율)	1,774 (5.5 %)	3,272 (7.2 %)	3,736 (7.5 %)
합계	32,085	45,501	**49,858**
직전 단계 대비 증가	-	+13,416 (병렬 데이터패스)	+4,357 (적응형 경로)
평균 처리 cycle	1,334	985	851.8

순차 소자 면적은 각 설계의 Yosys 합성 통계(synth_stat)에서 읽은 값이다.

배치와 전역 배선 이후 결과: 위 값은 합성 직후의 추정이므로, Reference 와 AdaPath_A 를 같은 SDC 규칙과 2 ns 클럭 제약으로 ORFS 전체 흐름에 넣어 배치, 클럭 트리 합성(CTS), 전역 배선까지 수행하였다(표 19). 상세 배선은 작업 PC 의 메모리 한도(10 GB)로 두 설계 모두 끝내지 못했으므로, 값은 전역 배선 기반 기생 성분과 실제 클럭 트리를 반영한 결과이다. 면적은 Reference 보다 56.6 % 커서 합성 직후(55.4 %)와 거의 같았다. 반면 환산 Fmax 는 Reference 574.7 MHz, AdaPath_A 509.6 MHz 로 차이가 11.3 %로 커졌다. AdaPath_A 의 임계 경로는 FSM 상태 레지스터에서 Conv2 MAC 레지스터들로 퍼지는 enable 신호로, 신호 하나가 많은 레지스터를 구동하면서 배선 지연이 커진 것이다. **Top-2 Finder 를 포함한 판단 회로는 임계 경로가 아니었다**. 이 Fmax 로 환산한 추론 지연은 Reference 2,321 ns, AdaPath_A 1,672 ns 로 AdaPath_A 가 여전히 28.0 % 짧다. FSM enable 신호를 복제하거나 한 단 파이프라인하면 이 경로를 줄일 수 있다(4.2 절).

[표 19] 배치 및 전역 배선 후 비교 (ORFS, ASAP7, 2,000 ps 제약, 상세 배선 전)

항목	Reference	AdaPath_A	변화
표준셀 면적 (μm²)	32,330	50,614	56.6 % 증가
2,000 ps 에서 최악 setup slack (ps)	+259.9	+37.6	-
클럭 skew (ps)	40.4	55.1	-
환산 Fmax (MHz)	574.7	509.6	11.3 % 감소
추론 지연 @환산 Fmax (ns)	2,321	1,672	28.0 % 감소

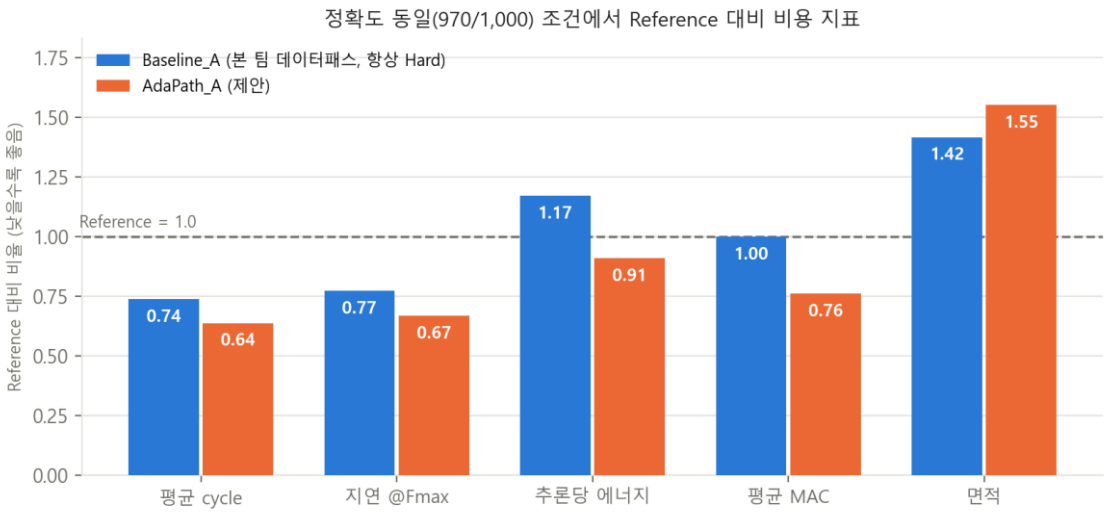
두 설계의 임계 경로가 모두 레지스터 간 경로이므로 최소 주기 = 2,000 ps − slack 으로 환산하였다. 2 ns 목표로 최적화한 배치 결과의 환산값이며, hold 위반은 없었다. 원시 리포트는 orfs/reports_postlayout/에 있다.

3.7 게이트레벨 VCD 기반 전력 및 추론당 에너지

벡터 없는(vectorless) 전력 추정은 기본 또는 지정 활동률을 적용하므로 입력별 모드 활성 패턴을 충분히 반영하지 못한다. 따라서 합성 넷리스트를 ASAP7 셀 모델로 게이트레벨 시뮬레이션(Icarus Verilog, 100 MHz)하여 **스위칭 파형(VCD)을 추출하고, OpenSTA(read_vcd)로 평균 전력을 계산하였다**. 한 런의 에너지는 E_run = P_avg × (t_end − t_start), 추론당 평균 에너지는 E_inf = E_run / N 이며, 측정 창에는 이미지마다 12 cycle 의 리셋 구간이 포함된다. 모드별 에너지는 Easy 4 장 런(이미지 1~4)과 Hard 1 장+Easy 3 장 런(이미지 5~8)의 차감으로 분리하였다(모델 B 의 Medium 은 이미지 15~18 런 사용). Reference 는 같은 이미지 12 장, Baseline_A 는 4 장의 평균이다. 따라서 모드별 값은 소수 대표 런 기반 추정이며, 서로 다른 Easy 이미지의 에너지가 같다는 근사를 포함한다.

[표 20] 모드별 추론당 에너지 (게이트레벨 VCD 기반 추정, 100 MHz)

설계 / 모드	에너지 (nJ)	Reference 대비
Reference (전체 경로)	17.7	-
Baseline_A (항상 Hard)	20.8	17.2 % 증가
AdaPath_A — Easy	15.8	11.0 % 감소
AdaPath_A — Hard	25.1	41.8 % 증가
AdaPath_A 가중 평균 (Easy / Hard = 96 / 4 %)	**16.2**	**8.9 % 감소**
AdaPath_B 가중 평균 (확장 모델)	19.8	11.6 % 증가

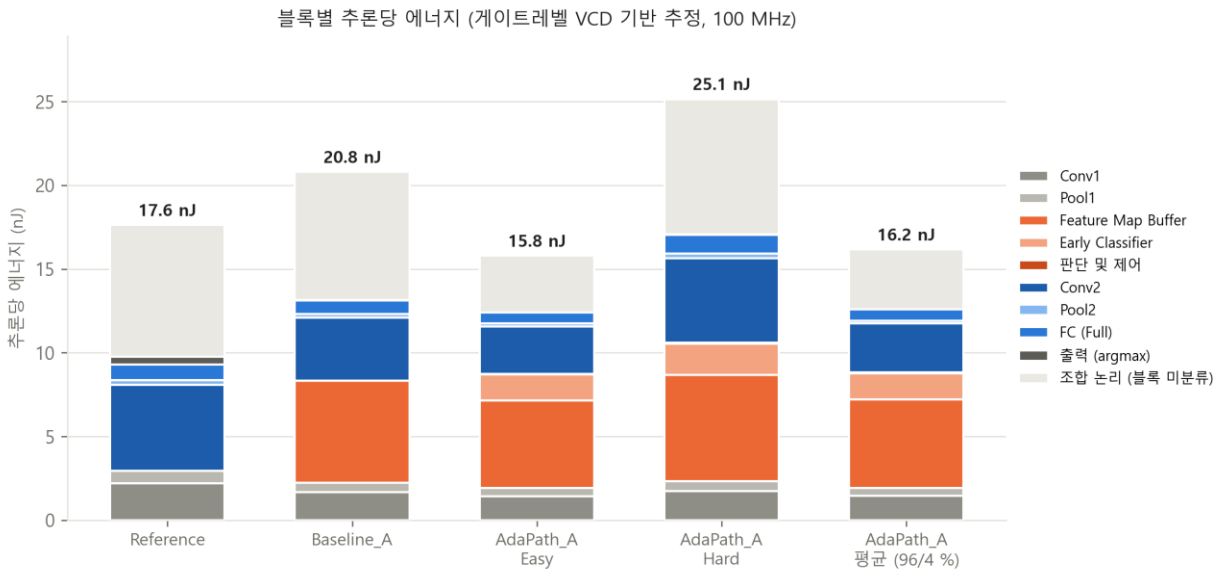


[그림 18] 정확도 동일(970/1,000) 조건에서 Reference 대비 처리 cycle, 지연, 에너지, MAC, 면적 (Reference = 1.0)

에너지 결과는 두 단계로 해석된다. 본 팀 데이터패스(Baseline_A)는 처리 cycle 을 26 % 줄였지만 Feature Map Buffer 등 레지스터가 늘어 추론당 에너지는 Reference 보다 17.2 % 많았다. 여기에 AdaPath 적응 경로가 같은 데이터패스 대비 에너지를 22.3 % 줄여, **최종적으로 Reference 대비 8.9 %의 에너지 감소를 얻었다**. 두 감소율은 비교 분모가 다르므로 합산하지 않는다. 또한

AdaPath_A 는 Reference 대비 평균 실행 MAC 을 23.8 % 줄이지만 에너지 감소율은 이보다 작으며, 그 차이는 특징 저장과 Early Classifier, 제어 회로 및 순차 소자의 전력 때문이다. 셀 면적은 55.4 % 증가하므로, 본 결과는 **면적을 추가로 사용하여 추론 지연과 에너지를 줄인 동작점으로 해석한다**.

에너지가 어디서 소모되는지 확인하기 위해 셀 단위 전력을 블록별로 합산하였다(그림 19). 합성 과정에서 이름이 유지되는 레지스터는 소속 블록으로, 이름이 없는 조합 논리는 하나의 항목으로 집계하였다. 세 가지가 확인된다. ① **연산 생략 효과는 조합 논리에서 뚜렷하다**. Easy 에서 조합 논리 에너지는 3.39 nJ 로 Baseline_A(7.65 nJ)의 절반 이하이다. ② 반면 **Easy 에서도 Conv2, Pool2, FC 의 레지스터는 연산 없이 클럭만 공급받으며 3.65 nJ(Easy 에너지의 23 %)**를 소모한다. ③ Feature Map Buffer(5,184 bit 레지스터)는 **Easy 에서 5.24 nJ(33 %)로 가장 큰 단일 블록이다**. 이 분석은 CTS 이전이라 클럭망 전력이 포함되지 않았으며(Easy 런에서 순차 소자 비중 79 %), 배치와 배선 이후 다시 평가해야 한다.



[그림 19] 블록별 추론당 에너지 (게이트레벨 VCD 기반 추정, 100 MHz; Reference 는 이미지 1~4 런, Hard 는 런 차감 추정)

②의 유휴 에너지는 Easy 판정 시 후단부 레지스터의 클럭을 차단하는 **클럭 게이팅의 직접적인 대상이다**. 이 에너지를 모두 제거할 수 있다고 가정한 상한 추정에서 Easy 에너지는 12.1 nJ, 가중 평균은 12.7 nJ 로 Reference 대비 28.7 % 감소한다. 이는 다른 에너지 항목을 고정하고 해당 유휴 에너지만 제거한 이상적 계산값이며, ICG 와 게이팅 제어의 오버헤드는 포함하지 않았다. 실제 구현에서는 합성 매핑과 게이팅 범위도 달라질 수 있으므로, 뒤의 구현 평가 결과와 구분한다.

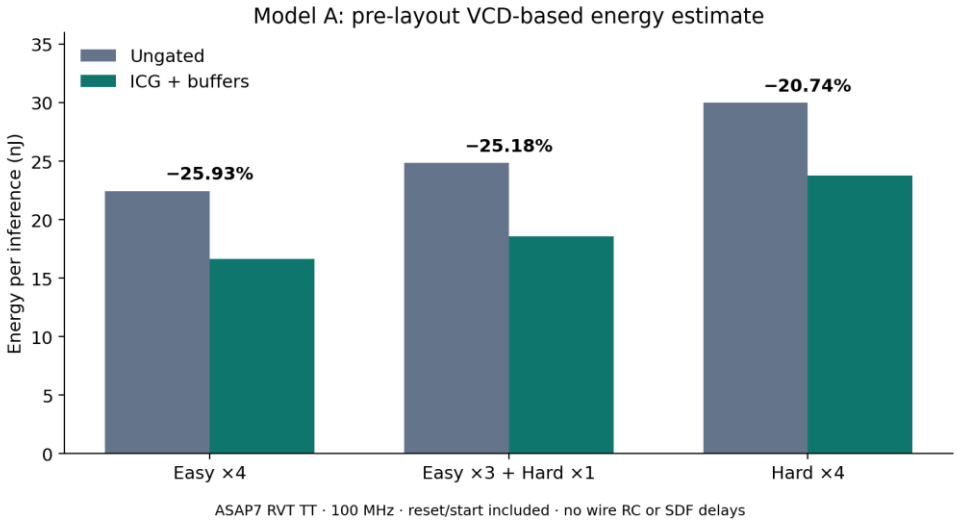
전용 ICG 적용 후 배치 전 전력 평가: 이 상한 추정을 실제 회로로 확인하기 위해, 모델 A 의 후단 Conv2, Pooling, FC 레지스터에 ASAP7 전용 ICG 셀(ICGx1_ASAP7_75t_R)을 넣은 설계를 따로 합성하여 게이팅 전 설계와 비교하였다(표 21). 두 설계 모두 같은 흐름, ASAP7 RVT TT, 100 MHz 에서 합성

넷리스트에 같은 버퍼 셀과 최대 분기 수 4 의 클럭 트리를 구성하여 ICG 와 버퍼의 부하 비용을 포함하였다. **Easy 4 장 구간의 이미지당 에너지는 25.9 %, Easy 3 장과 Hard 1 장의 혼합 구간은 25.2 %, Hard 4 장 구간은 20.7 % 줄었다**. Hard 에서도 후단부가 매 cycle 동작하는 것은 아니므로 게이팅 효과가 나타난다. ICG 를 넣은 RTL 은 1,000 회 순차 입력에서 기존 설계와 판정, 모드, margin, cycle 이 모두 같았고(970 / 1,000), 버퍼를 포함한 최종 넷리스트의 24 회 실행 출력도 기존 RTL 과 일치하였다. 다만 이 비교는 배치와 배선의 기생 성분을 포함하지 않는 배치 전 추정이고, 11 개 고유 입력으로 구성한 세 구간의 결과이며, 별도 합성에 따른 조합 논리 매핑 차이도 포함한다. 같은 조건의 Reference 재측정은 하지 않았으므로 이 감소율을 Reference 대비 개선율과 결합하지 않는다.

[표 21] 전용 ICG 적용 전후의 구간별 배치 전 전력과 에너지 (AdaPath_A, ASAP7 RVT TT, 100 MHz)

측정 구간 (4 회 추론)	게이팅 전 (mW)	ICG 적용 (mW)	게이팅 전 (nJ/장)	ICG 적용 (nJ/장)	감소율
Easy 4 장	2.616	1.938	22.44	16.63	25.9 %
Easy 3 장 + Hard 1 장	2.759	2.064	24.85	18.59	25.2 %
Hard 4 장	2.917	2.312	30.01	23.79	20.7 %

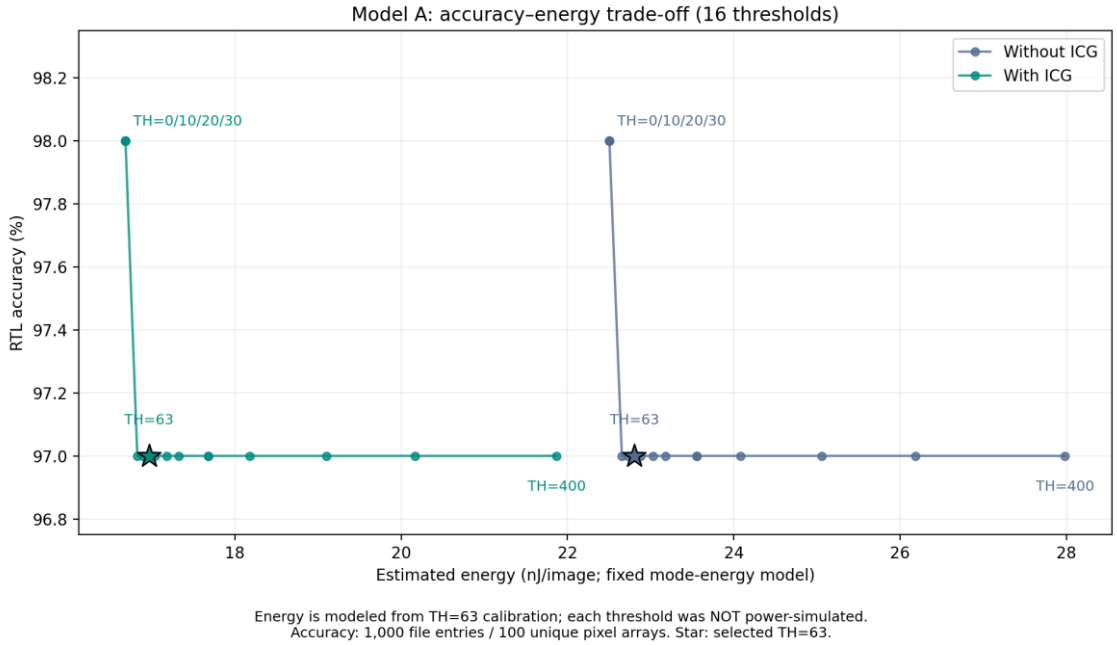
두 설계 모두 같은 팬아웃 제한 버퍼 클럭 트리를 넣은 값이라, 버퍼가 없는 3.7 절 앞부분의 블록별 에너지와 절대값이 다르다. 에너지는 VCD 구간 평균 전력 × 관측 시간 ÷ 4(reset 과 start 포함)이다.



[그림 20] 전용 ICG 적용 전후의 구간별 추론당 에너지 (AdaPath_A, ASAP7 RVT TT, 100 MHz, 배치 전 VCD 기반 추정)

같은 조건에서 고유 입력 40 개로 평가 범위를 확장하였다. Easy 36 장은 4 장씩 9 개 구간으로 구성하고, Hard 는 기존과 같은 4 장 1 구간의 결과를 사용하였다. **Easy 이미지당 에너지가 22.50 nJ 에서 16.68 nJ 로 평균 25.9 % 감소하였다**. 게이팅 전후 표준편차는 모두 약 0.15 nJ 이며, 이는 9 개 구간 평균의 표준편차(n = 9)로 개별 이미지의 편차가 아니다. 모델 A 에서 Hard 비율은 4 %이며, Hard 는 여전히 4 장 1 구간으로 표본이 적다. 본 결과는 배치 전 활동도 기반 추정이며 Reference 대비 개선율과 결합하지 않는다.

임계값별 정확도와 에너지의 계산 모델: 임계값 선택에 따른 정확도와 에너지의 상충 관계를 살펴보기 위해, 3.5.6 절 RTL 스윕의 정답 수와 모드 비율에 위의 TH = 63 표본(Easy 36 장, Hard 4 장)에서 얻은 모드별 에너지를 가중한 모델을 만들었다(그림 21). 즉 E(TH) = p_Easy(TH) × E_Easy + p_Hard(TH) × E_Hard 이며, **각 임계값의 전력을 직접 시뮬레이션한 값이 아니다**. 이 모델에서 TH = 0, 10, 20, 30 은 정답 980 개와 게이팅 적용 추정 에너지 16.68 nJ/장으로 같은 비지배점에 위치하였고, 선정 동작점 TH = 63 은 정답 970 개와 16.97 nJ/장이었다. 따라서 본 평가 입력과 고정 모드 에너지 모델에서는 TH = 63 을 최적 임계값으로 해석할 수 없다. 다만 임계값이 바뀌면 각 모드에 속하는 입력 구성도 바뀌므로(예: TH = 400 의 Hard 730 장을 TH = 63 의 Hard 4 장 평균으로 대표) 이 가정은 직접 검증되지 않았고, 같은 평가 입력으로 사후 선정한 결과는 독립 검증이 아니다. 입력도 고유 100 장의 반복이다. 이 때문에 별도 검증 집합과 임계값별 활동도 분석 없이 설계 동작점을 변경하지 않았다.



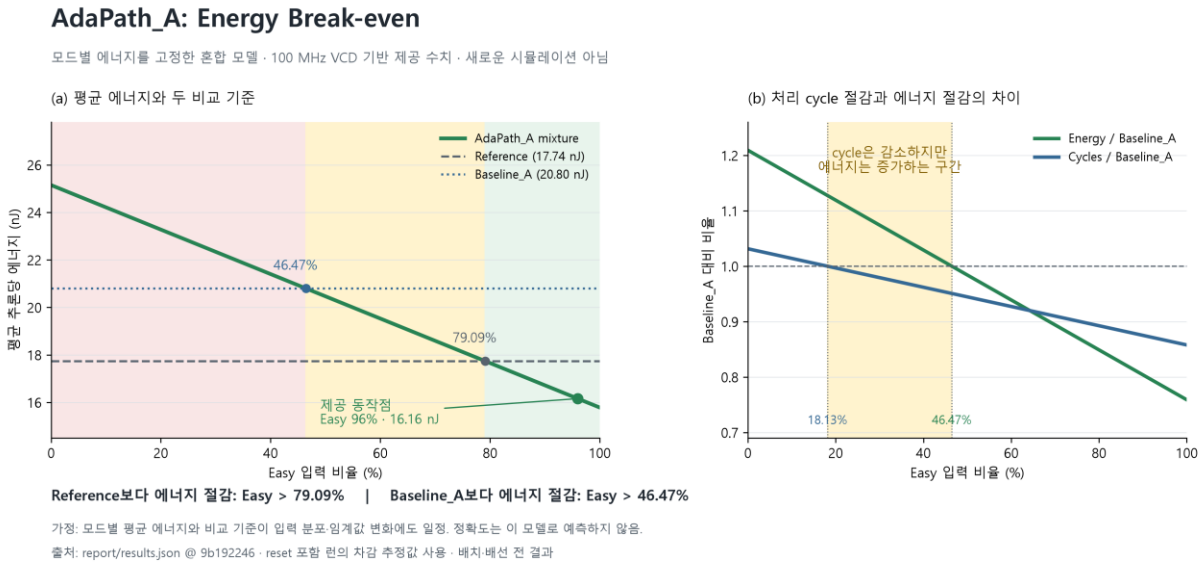
[그림 21] 모델 A 의 임계값별 정확도와 추정 에너지 (정확도는 1,000 회 입력의 RTL 스윕, 에너지는 TH = 63 의 모드별 VCD 기반 추정에 모드 비율을 가중한 계산값). 별표는 선정값 TH = 63, TH = 0, 10, 20, 30 은 서로 겹치는 비지배점이다.

[표 22] 효율 지표

설계	실행 MAC	에너지 (nJ)	실효 TOPS/W	등가 TOPS/W
Reference	58,080	17.7	6.55	6.55
Baseline_A	58,080	20.8	5.59	5.59
AdaPath_A	44,275	16.2	5.48	**7.19**

1 MAC = 2 operations. 실효 TOPS/W = 2 × 실행 MAC / 추론당 에너지. 등가 TOPS/W = 2 × Reference MAC(58,080) / 추론당 에너지로, 같은 분류 작업을 완료하는 효율이다. 본 측정에서는 실행 MAC 감소율이 에너지 감소율보다 커서 AdaPath_A 의 실효 지표가 낮아졌으므로, 두 지표를 평균 에너지 및 정확도와 함께 제시한다.

모드별 에너지를 고정한 혼합 모델로 입력 분포에 따른 에너지 이득 조건을 분석하였다(그림 22). Easy 비율을 p 라 하면 모델 A 의 평균 에너지는 E_A(p) = 25.15 − 9.37×p nJ 이다. 이 모델에서 Reference 대비 에너지 이득은 Easy 비율이 약 **79.1 %를 넘을 때** 발생하고, Baseline_A 대비 손익분기점은 약 46.5 %이다. 반면 Baseline_A 대비 처리 cycle 의 손익분기점은 약 18.1 %이므로, Easy 비율 18~46 % 구간에서는 처리 cycle 이 줄어도 에너지는 늘어날 수 있다. 즉 **처리 cycle 이나 MAC 감소만으로 에너지 이득을 보장할 수 없음을 정량적으로 보여준다**. 이 분석은 소수 대표 입력에서 유도한 모드별 에너지를 사용한 추정이며, 입력 분포가 바뀔 때의 모드별 에너지와 정확도 변화는 별도 검증이 필요하다.



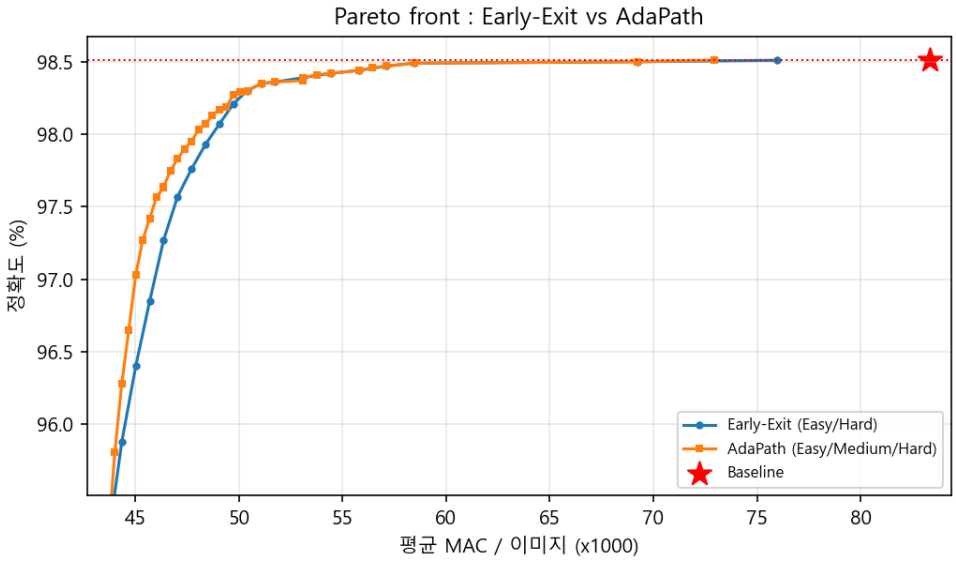
[그림 22] 모드별 에너지 고정 가정에서의 AdaPath_A 에너지 손익분기점 (기존 결과를 이용한 계산 모델)

3.8 Medium 경로의 기여 분리

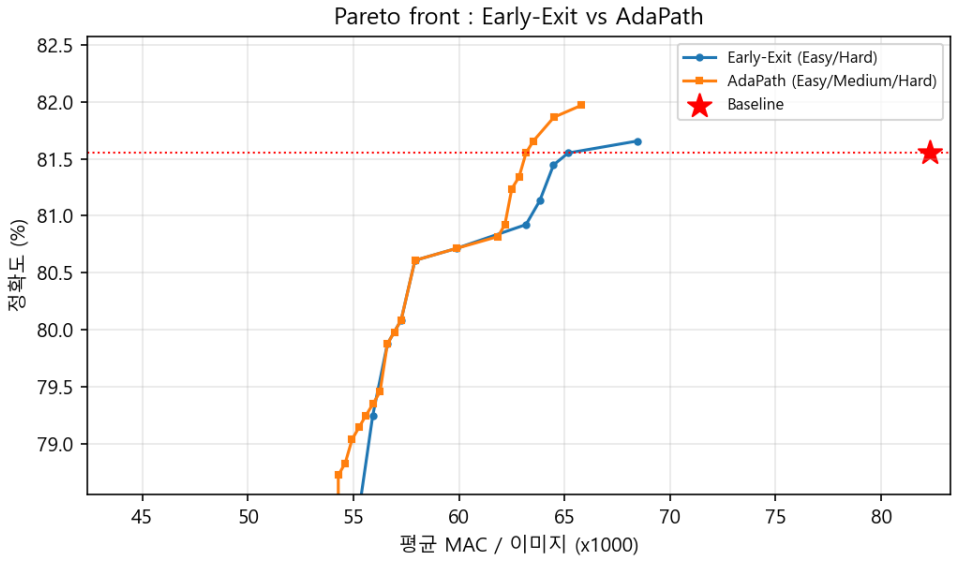
Medium 경로의 순수 기여를 분리하기 위해, 같은 Early Classifier 와 Score Margin 을 쓰되 **Medium 이 없는 Early-Exit(2 경로)와 AdaPath(3 경로)를 임계값 전수 탐색으로 비교하였다**(같은 정확도 제약에서의 최소 평균 MAC).

[표 23] Early-Exit 대비 AdaPath(Medium 추가)의 이득

조건	MNIST (모델 B)	WM-811K (모델 B)
같은 정확도 제약에서 추가 MAC 절감	0 ~ 2.2 %	2 ~ 3 %
동일 MAC 에서 정확도 향상 (공격적 절감 구간)	최대 +0.19 %p	최대 +1.68 %p
Baseline 정확도 근처	차이 없음	거의 차이 없음
모델 A (Conv2 3 채널)	Medium 미선택 (2 경로로 수렴)	-



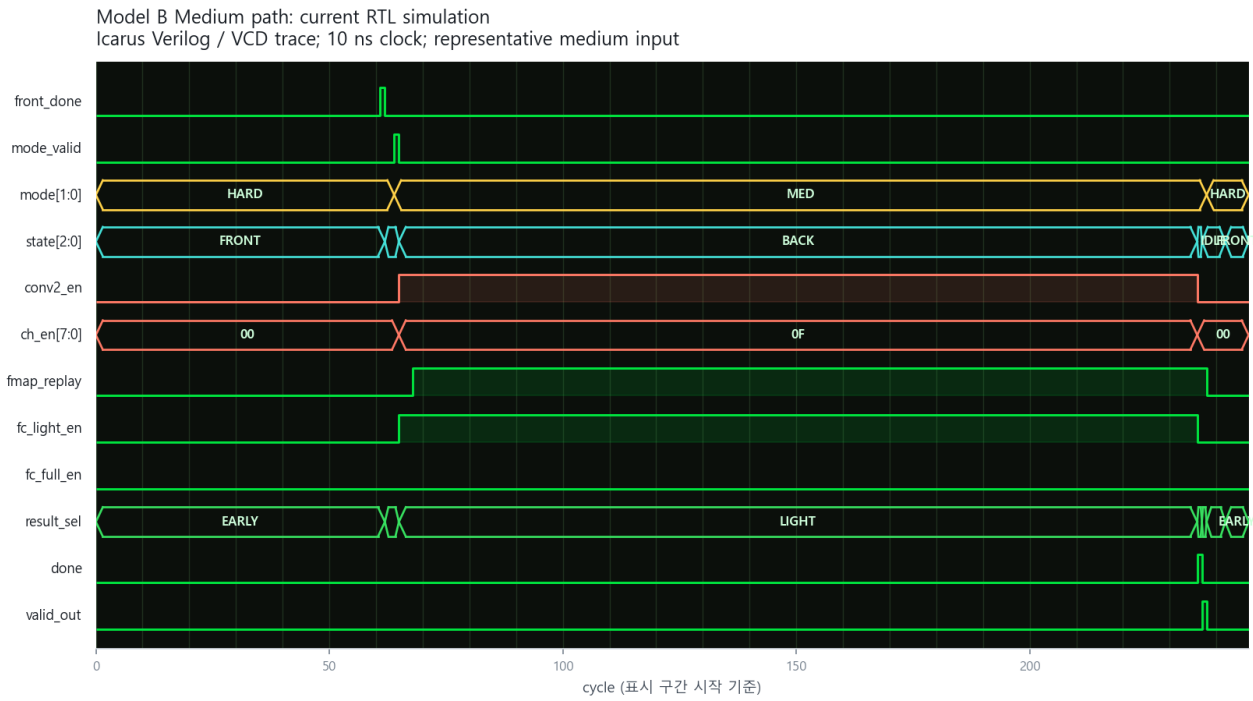
[그림 23] Pareto front 비교: Early-Exit vs AdaPath (MNIST, 모델 B)



[그림 24] Pareto front 비교: Early-Exit vs AdaPath (WM-811K)

평가한 조건에서 Medium 경로의 추가 MAC 절감은 MNIST 모델 B 에서 0~2.2 %, WM 에서 2~3 %였으며, Baseline 정확도 근처에서는 이득이 작았다. **Medium 은 공격적으로 연산을 줄이는 동작점에서 효과가 크며**, 임계값 탐색은 Medium 이 불리한 경우 이를 사용하지 않는 동작점(모델 A)도 선택할 수 있다.

Medium 경로의 하드웨어 동작을 추가 확인하기 위해 현재 RTL 과 모델 B 가중치로 기존 tb_adapath 를 다시 실행하였다. Easy/Hard/Medium 각 3 개 입력을 포함하는 **9 개 사례 모두 margin, mode, decision 이 정수 Golden 과 일치하였다**. Medium BACK 구간 총 513 cycle 에서 ch_en=0x0F, fc_light_en=1, fc_full_en=0 의 관찰 위반은 0 회였다. 이는 대표 사례의 동작 검증이며 전체 입력 공간에 대한 형식 검증은 아니다.



[그림 25] 모델 B Medium 경로의 실제 VCD 파형. 현재 RTL 의 Icarus 재실행에서 추출한 신호를 시각화하였으며 EDA 도구 화면 캡처는 아니다.

3.9 자유주제: WM-811K 웨이퍼맵 결함 분류 적용

반도체 제조 공정의 웨이퍼맵 결함 패턴(WM-811K, 811,457 장 중 라벨 172,950 장)에서 정상(none), Center, Edge-Ring, Scratch 4 개 클래스를 클래스당 같은 개수(가장 적은 Scratch 기준 약 1,190 장)로 균형 추출하고, 웨이퍼 맵(웨이퍼 밖 / 정상 die / 불량 die)을 28×28 로 리사이즈한 뒤 8:2 로 학습과 테스트를 나누었다. **모델 B 구조(4 개 클래스 출력)에 같은 AdaPath 기법을 적용하였으며**, 데이터 준비, 학습, 정수화, RTL 생성은 MNIST 와 동일한 코드로 수행하였다. 선정 동작점은 정확도 0.31 %p 하락을 수용하고 연산량을 줄인 지점이다.

[표 24] WM-811K 적용 전후 비교 (Baseline_WM = 항상 Hard)

항목	Baseline_WM	AdaPath_WM	변화
정확도 (테스트 954 장, float)	81.55 %	81.24 %	0.31 %p 하락
모드 개수 (Easy / Medium / Hard)	0 / 0 / 954	401 / 152 / 401 (42.0 / 15.9 / 42.0 %)	-
평균 MAC / 이미지	82,112	62,848	23.5 % 감소
Cell Area (μm²)	75,765	92,892	22.6 % 증가
추정 Fmax (MHz)	484.5	495.3	-
평균 cycle (10-class cycle 가정)	985	944	4.1 % 감소
추론당 에너지 (nJ, 대리 추정)	33.4	26.2	21.7 % 감소

cycle 행은 10-class MNIST 의 Baseline 985, Easy 845, 후단 1,016 cycle 을 WM float 모드 비율로 가중한 기존 계산값이며, 4-class WM RTL 의 실측 cycle 이 아니다. WM 에너지는 10 개 클래스 AdaPath_B 의 모드별 VCD 기반 에너지에 WM-811K 모드 비율을 가중한 대리 추정이다. Baseline_WM 값으로 AdaPath_B Hard 에너지를 사용하였으나 Baseline_WM 에는 Early 경로가 없으므로, **4 개 클래스 설계의 직접 전력 측정 결과와 구분한다**.

3.9.1 RTL 검증 (Vivado)

자유주제 설계도 지정주제와 같은 chip 인터페이스 래퍼(클래스 수만 4 로 설정)로 Vivado 프로젝트를 구성하고, 주최 측 TB 와 같은 방식(이미지마다 리셋 후 1 px/cycle 스트리밍)으로 WM-811K 테스트 954 장을 처리하였다(표 25). **판정, 모드, Score Margin 이 정수 Golden 과 954 장 모두 비트 단위로 일치하였고**, 정확도는 774 / 954 = 81.13 % (정수 Hard 경로 단독 81.45 %)였다. 모드는 Easy 404 / Medium 167 / Hard 383 장으로, **3 경로가 모두 하드웨어에서 실제로 사용**되었다(MNIST 모델 A 는 2 경로). 정수 임계값(13 / 41) 기준이라 float 분석의 모드 비율(401 / 152 / 401)과 약간 다르며, 이 비율을 에너지 대리 추정에 적용해도 26.1 nJ 로 거의 같다. 제출용 프로젝트(PPA_AdaPath_NPU_WM)는 다른 폴더로 옮겨 실행해도 같은 결과를 얻었다.

[표 25] WM-811K RTL 검증 결과 (Vivado 2023.1, 정수 연산, 테스트 954 장)

클래스	n	AdaPath RTL recall	정수 Hard 경로 recall
none (정상)	245	179 (73.1 %)	182 (74.3 %)
Center	251	238 (94.8 %)	235 (93.6 %)
Edge-Ring	230	216 (93.9 %)	215 (93.5 %)
Scratch	228	141 (61.8 %)	145 (63.6 %)
전체	954	**774 (81.13 %)**	777 (81.45 %)

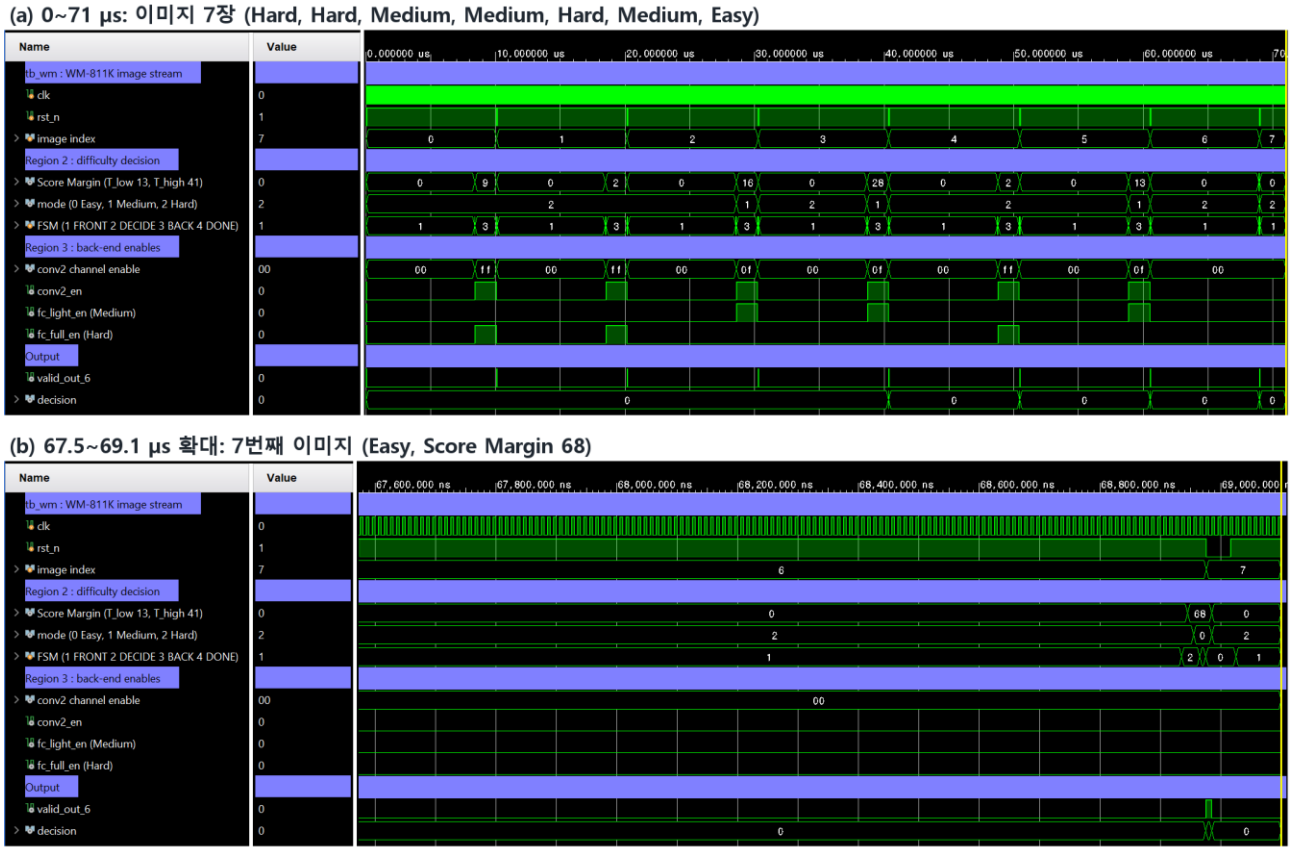
AdaPath RTL 은 Golden 판정과 954 / 954 일치. 모드 Easy / Medium / Hard = 404 / 167 / 383 (정수 임계값 13 / 41).

3.9.2 경로별 동작 파형과 제어 조건 검증 (Vivado)

세 경로가 하드웨어에서 실제로 다르게 동작하는지 같은 Vivado 프로젝트의 파형으로 확인하였다(그림 26). WM-811K 테스트 처음 7 장은 Hard, Hard, Medium, Medium, Hard, Medium, Easy 순으로 판정되었다. Hard 에서는 Conv2 8 채널 전체(ch_en = 0xFF)와 Full FC 가, Medium 에서는 하위 4 채널(0x0F)과 Light FC 가 켜졌다. Easy(Score Margin 68)에서는 Conv2 와 후단 Light/Full FC 를

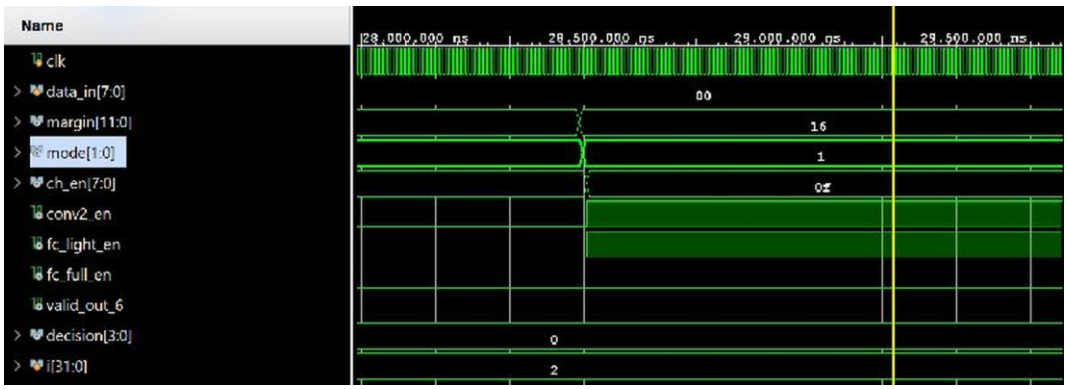
비활성화하고 Early 점수로 출력하였다. 관측기의 start→valid 상승 에지 간격은 Easy 839 cycle, Medium 과 Hard 각각 1,004 cycle 이었다(WM_transactions.csv). **Medium 은 Hard 와 같은 응답 cycle 수를 사용하면서 후단부 활성 채널과 FC 연산량을 줄인다**.

동일한 관측기 정의로 집계한 WM 954 장의 평균은 934.13 cycle 이었다((404 × 839 + 550 × 1,004) / 954).



[그림 26] Vivado 파형 (WM-811K): 처음 7 개 입력의 경로별 후단부 enable 과 Easy 출력 구간 확대. 10 ns 클럭의 기능 시뮬레이션이다.

실제 제출용 WM 프로젝트의 세 번째 입력(index 2)을 Vivado 2024.1 에서 관측한 결과, 정수 Score Margin 은 16 으로 13 ≤ margin < 41 을 만족하여 mode = 1(Medium)이 선택되었다(그림 27). 후단 활성 구간 28.605~30.255 µs 에서 ch_en = 0x0F, Conv2 및 Light FC 활성, Full FC 비활성이 확인되었다. 이후 원시 VCD 의 30.265~30.275 µs 구간에서 valid_out_6 = 1 과 decision = 0 이 관측되어 정답 및 Golden 과 일치하였다. 출력 이후의 mode = 2 는 다음 입력을 위한 리셋 기본값이다.



[그림 27] Vivado 파형 확대 (WM-811K 세 번째 입력, Medium 후단 활성 구간): margin 16, mode 1, ch_en 0x0F, fc_light_en 1, fc_full_en 0. 유효 출력 펄스는 이 캡처 이후이며 원시 VCD 에서 별도로 확인하였다.

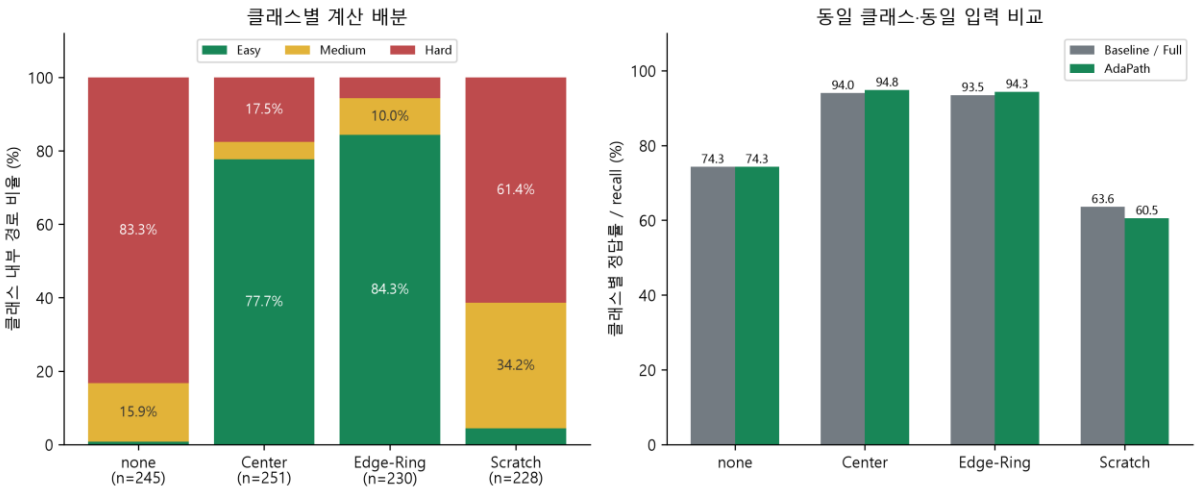
단일 파형 이외의 입력에 대한 제어 조건 검사 결과는 표 14 에 제시하였다. WM Medium 167 장의 27,555 개 활성 cycle 을 포함하여 검사된 조건의 위반은 0 건이었다. 모델 A 의 Medium 미실행, 마지막 start 미평가 및 초기 X 관측을 포함한 검증 범위와 제한사항은 3.5.5 절에 명시하였다.

3.9.3 클래스별 분석

전체 평균만으로는 결함 종류별 영향을 알 수 없으므로 클래스별 경로 배분과 정확도를 분석하였다(표 26, 그림 28). Edge-Ring(84.3 %)과 Center(77.7 %)는 대부분 Easy 로 조기 종료되며 AdaPath 정확도가 Full 보다 오히려 약간 높았다. 반면 정상(none)은 83.3 %가 Hard 로 갔고, Scratch 는 Easy 가 4.4 %에 그치며 **recall 이 Full 63.6 %에서 AdaPath 60.5 %로 3.1 %p 낮아졌다**. 즉 **계산 배분은 패턴의 물리적 복잡성보다 현재 전단 분류기의 구분 능력을 따르며**, '정상은 쉽고 결함은 어렵다'고 단순화할 수 없다. 공정 검사에서는 결함을 정상으로 놓치는 비용이 크므로(결함→정상 오분류: Full 91 건, AdaPath 91 건으로 동일), 평균 MAC 최적화와 함께 클래스별 recall 제약을 함께 검토해야 한다. 혼동 행렬은 부록 C 에 수록하였다.

[표 26] WM-811K 클래스별 경로 배분과 정확도 (기존 동작점, 테스트 954 장, Python float)

클래스	n	Easy / Medium / Hard (%)	Full recall (%)	AdaPath recall (%)	차이 (%p)
none (정상)	245	0.8 / 15.9 / 83.3	74.3	74.3	0.0
Center	251	77.7 / 4.8 / 17.5	94.0	94.8	+0.8
Edge-Ring	230	84.3 / 10.0 / 5.7	93.5	94.3	+0.9
Scratch	228	4.4 / 34.2 / 61.4	63.6	60.5	−3.1



[그림 28] WM-811K 클래스별 경로 배분(Easy/Medium/Hard)과 Full 및 AdaPath recall

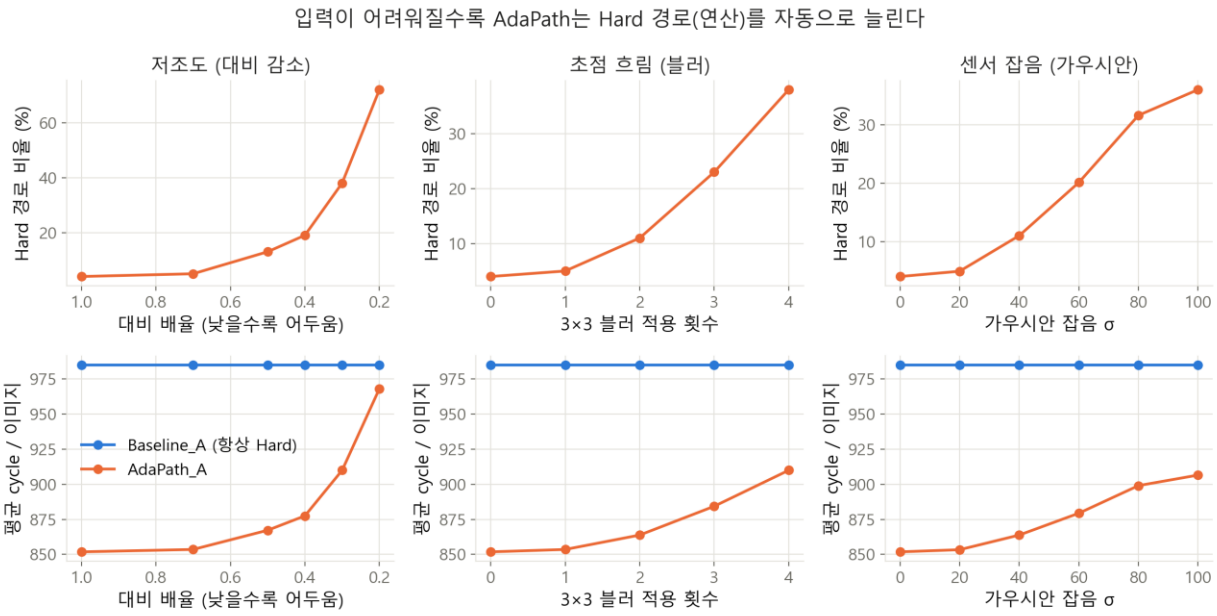
3.10 입력 열화에 따른 적응적 연산 배분 (RTL 실측)

입력이 어려워질 때 AdaPath 가 실제로 후단 연산을 더 많이 사용하는지 확인하기 위해, 주최 측 입력 1,000 회에 실제 센서 환경을 모사한 열화(대비 감소 6 단계, 3×3 블러 5 단계, 가우시안 잡음 6 단계, seed 고정)를 적용하고 모델 A 의 AdaPath_A 와 같은 가중치의 항상-Hard 설계(Baseline_A)를 RTL 로 각각 실행하였다(총 34 회, 그림 29 및 30). 원본과 대비 0.3 조건의 기준값을 먼저 재현한 뒤 전체를 실행하였다.

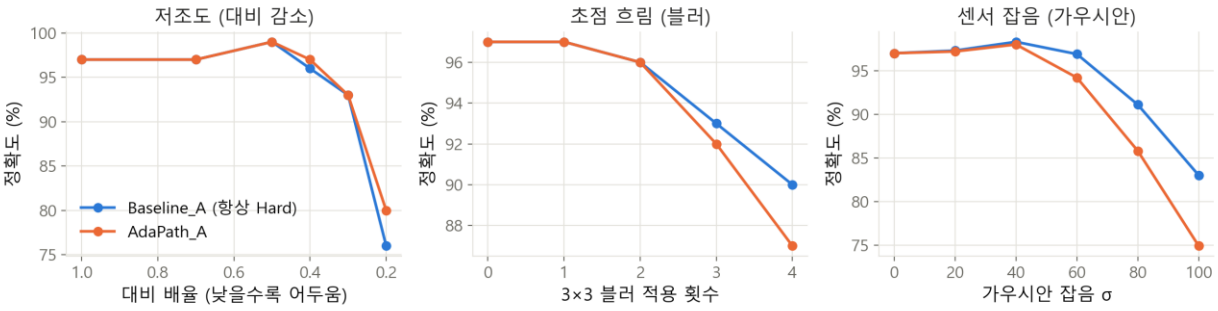
[표 27] 입력 열화 생성 조건

종류	수준	변환 및 처리
대비 축소	1.0, 0.7, 0.5, 0.4, 0.3, 0.2	픽셀값에 계수 c 를 곱함
평균 블러	0, 1, 2, 3, 4 회	영 패딩 3×3 평균 필터를 반복 적용
가우시안 잡음	σ=0, 20, 40, 60, 80, 100	픽셀 단위 $N(0, \sigma^2)$ 가산, seed=2026

변환 후 np.rint 로 반올림하고 [0,255]로 포화시켰다. σ 는 8-bit 픽셀값 단위이다. 종류별 수준을 나열된 순서로 생성하며 난수 생성기의 상태를 이어 사용하였다.



[그림 29] 입력 열화 강도에 따른 AdaPath_A 의 Hard 경로 비율(위)과 평균 처리 cycle(아래) (RTL 실측)



[그림 30] 입력 열화 강도에 따른 정확도: AdaPath_A vs Baseline_A (RTL 실측)

세 열화 모두에서 열화가 강해질수록 Hard 비율과 평균 cycle 이 증가하였다. 특히 대비를 1.0 에서 0.2 로 낮추면 **Hard 비율이 4 %에서 72 %로 늘어**, **평가한 열화 수준에 따라 연산을 더 배분하는 동작**이 RTL 에서 확인되었다. 대비 감소에서는 정확도가 Baseline_A 와 같거나 높았다(0.2 에서 80.0 % vs 76.0 %). 반면 강한 블러(4 회, 87.0 % vs 90.0 %)와 **강한 가우시안 잡음(σ = 100, 74.9 % vs 83.0 %)에서는 AdaPath 의 정확도가 낮았다**. 이 조건에서는 Hard 비율이 36~38 %에 머물러, 일부 입력이 높은 Score Margin 으로 Easy 에서 종료된 것으로 보인다. 열화 입력을 포함한 학습이나 Early Classifier 보정으로 개선할 수 있다(4.2 절).

대비 0.3 에서는 AdaPath_A 와 Baseline_A 의 정확도가 93.0%로 같고 cycle 은 7.62% 감소하였다. 반면 σ=100 에서는 7.96%의 cycle 감소와 8.1%p 의 정확도 손실이 함께 나타났다. **큰 Score Margin 은 확률로 보정된 신뢰도가 아니므로** 'Early Classifier 가 확신을 갖고 틀리는 경우'가 가능하다. 무열화 입력의 오류 사례는 부록 C 에 제시하였다.

4. 결과 및 기대효과

4.1 결과 요약

[표 28] 최종 결과 요약 (지정주제: Reference 대비 AdaPath_A)

지표	Reference	AdaPath_A	변화
정답 (주최 입력 순차 1,000 회)	970	970	유지
평균 처리 cycle (순차 입력)	1,334	851.8	36.1 % 감소
추정 Fmax (MHz, pre-layout)	569.8	543.1	4.7 % 감소
추정 Fmax 에서의 추론 지연 (ns)	2,341	1,569	33.0 % 감소
평균 실행 MAC / 추론	58,080	44,275	23.8 % 감소
추론당 에너지 (nJ, VCD 기반 추정)	17.7	16.2	8.9 % 감소
Cell Area (μm²)	32,085	49,858	55.4 % 증가
등가 TOPS/W (같은 분류 작업 기준)	6.55	7.19	9.8 % 향상

[표 29] 단계별 설계 개선 (지정주제, 주최 입력 순차 1,000 회)

단계	설계 변경	정답	평균 cycle	Fmax (MHz)	추론 지연 (ns)	에너지 (nJ)	면적 (μm²)
① Reference	주최 측 가속기	970	1,334	569.8	2,341	17.7	32,085
② Baseline_A	스트리밍 데이터패스 (항상 전체 경로)	970	985	543.3	1,813	20.8	45,501
③ AdaPath_A	Early Classifier, Score Margin 경로 선택, 토너먼트 Top-2	970	851.8	543.1	1,569	16.2	49,858
④ + 후단부 ICG	Easy 판정 시 후단부 클럭 차단	970	851.8	-	-	구간별 −20.7~25.9 %	-
③의 Reference 대비		유지	36.1 % 감소	4.7 % 감소	33.0 % 감소	8.9 % 감소	55.4 % 증가

Fmax 와 추론 지연은 합성 직후 추정값이다. ④의 에너지는 클럭 트리를 넣은 같은 조건에서 ICG 적용 전 설계 대비 구간별 감소율이다(표 21).

TH=63 은 MNIST 테스트셋 10,000 장에서 Full 대비 정확도 손실 0.5 %p 이내로 연산을 최소화하도록 선정한 동작점이다. 주최 입력에서는 더 낮은 임계값(TH=0~30)도 정답 980 개와 평균 845.00 cycle 을 보였으며, 임계값은 레지스터로 런타임에 바꿀 수 있으므로(3.5.6 절) 응용의 입력 분포에 맞춰 동작점을 조정할 수 있다.

4.2 한계 및 향후 개선

- **배치 및 배선 후 전력:** 전력은 게이트레벨 VCD 기반의 배치 전 추정이다. 상세 배선 후의 기생 성분과 클럭망을 반영한 전력 평가로 클럭 게이팅 효과(표 21)를 다시 확인할 계획이다.

- **배치 후 임계 경로:** 배치와 전역 배선 후 임계 경로는 FSM 에서 Conv2 MAC 레지스터로 퍼지는 enable 신호였다(표 19). enable 레지스터를 복제하거나 한 단 파이프라인하여 Reference 와의 Fmax 차이를 줄일 수 있다.
- **열화 입력의 정확도:** 강한 블러와 잡음에서 정확도가 **Baseline_A 보다 최대 8.1 %p 낮았다**(3.10 절). 열화 입력을 포함한 학습과 Early Classifier 보정으로 개선할 수 있다.
- **면적:** 면적 증가분의 약 75 %는 병렬 데이터패스에서 발생한다(표 18). Conv1 병렬도를 응용의 처리량 요구에 맞추면 면적과 처리 속도 사이에서 동작점을 선택할 수 있으며, 적응형 경로의 추가 면적은 전체의 9 % 수준이다.
- **Feature Map Buffer:** 5,184 bit 레지스터 버퍼가 Easy 에너지의 33 %를 차지한다. **SRAM 매크로로 바꾸거나** Early Classifier 와 Full FC 의 연산기를 공유하여 면적과 에너지를 줄일 수 있다.

4.3 기대효과

- **엣지 AI 저전력화:** Early Classifier, 특징 버퍼, 판단 및 제어 회로를 추가하여 쉬운 입력의 후단 연산을 생략함으로써, 배터리 기반 엣지 기기의 추론당 에너지와 지연을 함께 줄일 수 있다. 모델 A 의 모드별 에너지를 고정한 혼합 모델에서는 Easy 비율이 약 79.1 %를 넘을 때 **Reference 대비 평균 에너지 감소가 추정되었다**. 다른 응용에도 같은 손익분기점이 적용되는지는 확인하지 않았다.
- **반도체 공정 검사 적용:** 웨이퍼맵 검사에서 Edge-Ring, Center 처럼 **명확한 패턴은 조기 종료하고 애매한 패턴만 정밀 경로로 보내는 계층적 검사**에 활용할 수 있다. 다만 Scratch recall 감소(3.9 절)처럼 결함 누락 비용이 큰 클래스는 별도 recall 제약과 함께 운용해야 한다.
- **설계 방법론:** 임계값 탐색 → 정수 Golden → 파라미터화 RTL → ORFS 합성 → 게이트레벨 VCD 전력까지 하나의 흐름으로 연결하여, **다른 모델 및 데이터셋에도 같은 절차로 적용할 수 있음을 보였다**.

4.4 결론

본 과제는 고정 경로 가속기가 쉬운 입력에도 전체 연산을 수행하는 낭비를 줄이기 위해, Early Classifier 점수의 Top-1 과 Top-2 차이(Score Margin)를 비교기와 감산기만으로 계산하여 입력마다 Easy, Medium, Hard 경로를 선택하는 AdaPath-NPU 를 설계하였다. 알고리즘 탐색, 정수 Golden 모델, 파라미터화 RTL, OpenROAD 합성과 배치, 게이트레벨 전력 분석, Vivado 기능 검증까지 하나의 흐름으로 연결하여 설계의 효과와 비용을 함께 정량화하였다.

지정주제(MNIST, 모델 A)에서는 주최 측 Reference 와 같은 정답 수(970 / 1,000)를 유지하면서 **평균 처리 cycle 36.1 % 감소, 추론 지연 33.0 % 감소, 추론당 에너지 8.9 % 감소**를 달성하였다. 추가 면적 55.4 % 증가의 대부분은 처리 cycle 을 줄인 병렬 데이터패스에서 발생하였고 판단 회로는 0.65 %에

불과하며, Top-2 Finder 를 토너먼트 트리로 바꾸어 판단 회로가 임계 경로가 되지 않게 하였다. 배치와 전역 배선 이후에도 추론 지연은 Reference 보다 28.0 % 짧았다. 블록별 에너지 분해로 Easy 경로에서 후단부 레지스터의 유휴 전력을 찾아냈고, 전용 ICG 셀로 이를 차단한 설계에서 **구간별 에너지를 추가로 20.7~25.9 % 줄였다**.

같은 RTL 을 파라미터만 바꾸어 확장 모델 B(MNIST, 주최 TB 정답 999 / 1,000)와 자유주제 웨이퍼맵 결함 분류(WM-811K, 4 개 클래스)에 적용하였다. WM-811K 에서는 Medium 경로가 실제로 선택되어 3 경로 제어가 동작함을 확인하였고, Vivado 에서 정확도 81.13 %(774 / 954)와 정수 Golden 대비 판정, 모드, Score Margin 954 / 954 일치를 얻었다. 기능 검증은 단위 회로, 1,000 장 회귀, 주최 측 테스트벤치, 제출 패키지의 독립 PC 재현, 합성 넷리스트의 Vivado 시뮬레이션(5 개 시드 부분 실행, 판정 1,007 회 일치, cycle 1,006/1,006 일치)까지 단계별로 수행하였다.

또한 본 과제는 **연산량(MAC) 감소가 곧 에너지 감소로 이어지지 않는다**는 점을 블록 단위로 보이고, 적응형 경로가 에너지에서 유리해지는 Easy 비율(약 79 %)을 손익분기점으로 제시하였다. 이는 적응형 추론 하드웨어를 설계할 때 경로 생략과 함께 유휴 블록의 클럭 차단과 버퍼 비용을 함께 설계해야 함을 보여준다. 향후에는 배치와 배선 이후의 전력 검증, enable 경로 파이프라인, Feature Map Buffer 의 SRAM 화를 통해 면적과 에너지 효율을 더 높일 계획이다.

※ 참고문헌

[1] S. Teerapittayanon, B. McDanel, H. T. Kung, "BranchyNet: Fast inference via early exiting from deep neural networks," ICPR, 2016.

[2] M.-J. Wu, J.-S. R. Jang, J.-L. Chen, "Wafer map failure pattern recognition and similarity ranking for large-scale data sets," IEEE Trans. Semiconductor Manufacturing, 2015. (WM-811K)

[3] Y. LeCun et al., "Gradient-based learning applied to document recognition," Proc. IEEE, 1998. (MNIST)

[4] L. T. Clark et al., "ASAP7: A 7-nm finFET predictive process design kit," Microelectronics Journal, 2016.

[5] T. Ajayi et al., "Toward an open-source digital flow: First learnings from the OpenROAD project," DAC, 2019.

[6] A. Kouris, S. I. Venieris, C.-S. Bouganis, "CascadeCNN: Pushing the performance limits of quantisation in convolutional neural networks," FPL, 2018.

[7] Y. Kaya, S. Hong, T. Dumitras, "Shallow-Deep Networks: Understanding and mitigating network overthinking," ICML, PMLR 97, pp. 3301–3310, 2019.

부록 A. 재현성

[표 30] 도구 및 실행 환경

항목	버전 / 설정	근거
Yosys (ABC 포함)	0.68+ (git a5af9d690)	합성 로그 배너
OpenROAD / OpenSTA	26Q3-1305-gf552262465 (ORFS 6101364b2, 2026-08-18)	STA 및 전력 리포트 배너
표준셀 라이브러리	ASAP7 7.5-track RVT, TT corner (NLDM)	STA 및 전력 Tcl 의 Liberty 지정
Icarus Verilog	12.0 (devel) s20150603-1539-g2693dd32b	iverilog -V
Vivado	2023.1 (SW Build 3865809)	Vivado 실행 로그
Vivado (독립 PC 재검증)	2024.1	results_hs/submit_check/logs/
Python / PyTorch	3.13.2 / 2.10.0+cpu (학습 PC 환경)	학습 PC 에서 확인, 학습 당시 로그는 별도 보존하지 않음
게이트레벨 시뮬레이션	100 MHz(10 ns), 이미지마다 리셋 12 cycle, ASAP7 셀 모델(지연 0 기능 모델)	glsim TB

위 도구 표의 합성 및 전력 환경은 기존 Reference 비교 분석의 환경이다. 3.7 절의 전용 ICG 적용 전후 비교 및 고유 입력 40 개 확장 실험은 별도 환경인 WSL2 Ubuntu 24.04.5 LTS, Yosys 0.58(git 157aabb58), OpenROAD 26Q2-1164-g08f67ee5ec, ORFS 7bf5a814e47c54ec6c64692b464d398184d99891 및 Icarus Verilog 12.0 stable 을 사용하였다. 게이팅 전후 설계는 이 환경에서 동일 조건으로 비교하였으며, 기존 Reference 분석과 도구 버전이 같다는 의미는 아니다. 버전 원문 및 파일 해시는 results_hs/clock_gating/environment.json 에 보존하였다.

[표 31] 주요 실행 단계와 데이터

단계	명령 / 스크립트	데이터 및 조건
학습	python train.py --arch A --n_class 10 --prefix mnist	python/에서 실행; MNIST 학습 60,000 장, 30 epoch, seed 미고정
임계값 탐색	python analyze_margin.py --arch A --prefix mnist	python/에서 실행; MNIST 테스트 10,000 장 (동일셋 선정)
정수화	python export_int8.py --arch A --prefix mnist --t_low 1.161 --t_high 1.161	python/에서 실행; RTL 임계값 A 63/63, B 71/119, WM 13/41
RTL 검증	rtl/run_sim.sh, tb_batch1000.v, tb_official1000.v	Golden 대조, 주최 측 입력 1,000 회
합성 및 STA	ORFS make synth, flow_scripts/sta_one.sh, sta_sweep.tcl	동일 SDC 규칙, 주기 1.0~2.4 ns 스윕
전력	glsim/run_*.sh → flow_scripts/vcd_power_odb.tcl, blockpower.tcl	VCD 런 구성: evidence/README.md
Vivado 제출	vivado/submit/make_submit.tcl	top_tb_1000, 프로젝트 내부 상대 경로
Vivado 자유주제	vivado/submit/make_submit_wm.tcl	tb_wm, vivado/wm_data/의 954 장, 4 개 클래스
추가 분석	results_sh/v2/ (Python), results_hs/ (RTL 스윕 및 열화)	분할 seed 2026–2030, 열화 seed 2026

전체 스크립트, 원시 결과, 실행 로그는 팀 저장소(SafeGuard-EWHA/Pin_Pineapple_Applepen-PPA)에 보존하였다.

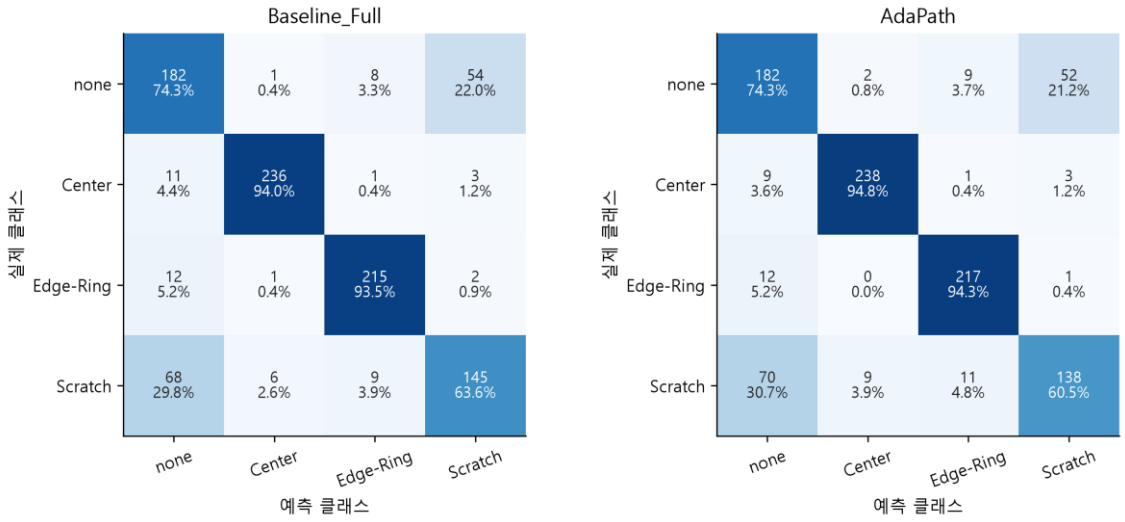
부록 B. 관련 연구 비교

[표 32] 조기 종료 및 동적 추론 선행 연구와 본 설계의 비교

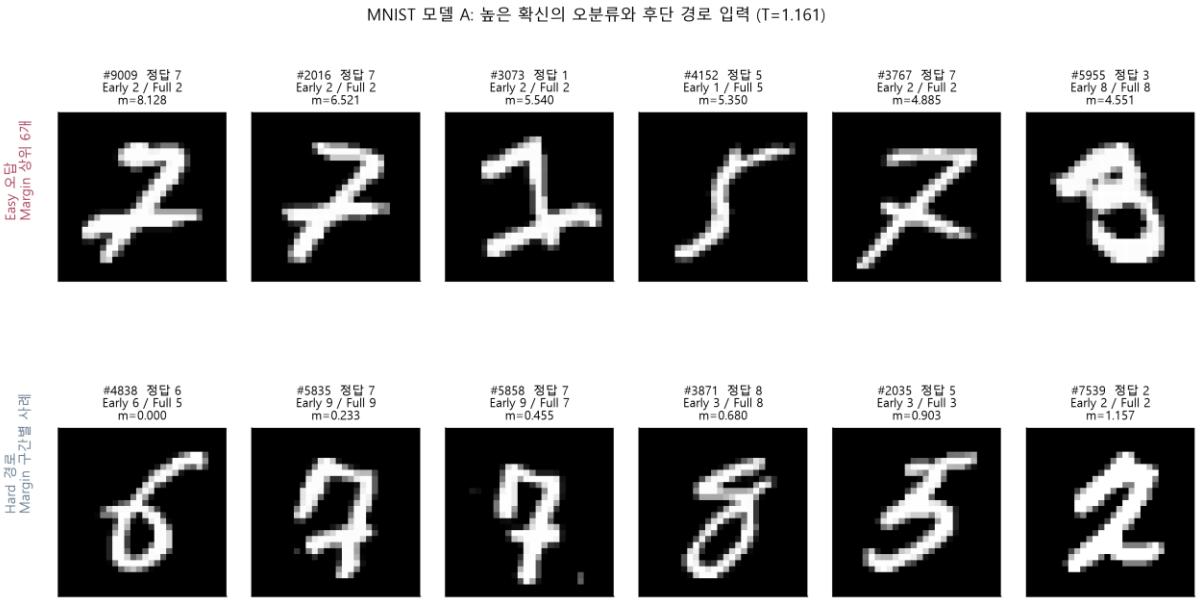
연구	판단 지표	경로 / 출구 수	구현	평가
BranchyNet [1]	softmax 엔트로피	LeNet 2, AlexNet/ResNet 3	CPU/GPU (전용 RTL 없음)	MNIST/CIFAR-10 정확도 및 추론 시간
CascadeCNN [6]	확률의 generalized Best-vs-Second-Best	2 (저정밀 종료 / 고정밀 재계산)	FPGA CNN + ARM CPU (softmax 및 판단)	ImageNet, FPGA 실측 처리량
Shallow-Deep Networks [7]	최대 클래스 확률	7 (내부 6 + 최종 1)	소프트웨어 (전용 RTL 없음)	CIFAR-10/100, Tiny ImageNet 정확도–FLOPs
AdaPath-NPU (본 설계)	정수 로짓 Top-1 – Top-2	A: 2, B: 3	Verilog RTL, ASAP7 합성 및 STA	MNIST/WM-811K, 게이트레벨 VCD 에너지

플랫폼, 모델 규모, 평가셋이 달라 수치를 직접 순위화하지 않는다.

부록 C. 추가 그림



[그림 31] WM-811K 4 개 클래스 혼동 행렬 (Full vs AdaPath, 칸마다 표본 수와 행 정규화 비율)



[그림 32] 모델 A 오류 사례: 위 = Easy 오답 중 Margin 상위 6 개, 아래 = Hard 입력의 Margin 분위별 사례 (정답, Early/Full 예측, Margin 표기)